Eksploracja danych
Lista nr 0
1 III 2025

UWAGA: ta lista zadań jest „rozgrzewkowa” $\Longrightarrow$ sprawozdanie NIE obowiązuje!

Uwagi do wszystkich zadań

- Zadania dotyczą zbioru danych **Cars93** dostępnego w R-pakiecie (bibliotece) *MASS*. Dla ułatwienia opis danych został umieszczony na ePortalu PWr. Podstawowe informacje o danych można również uzyskać wykonując w konsoli polecenie: `> help(Cars93)`.
- Zbiór *Cars93* wczytujemy do przestrzeni roboczej R'a następująco:
  ```
  > library(MASS) # wczytanie biblioteki MASS
  > data(Cars93) # wczytanie zbioru danych Cars93
  ```
- Bezpośredni dostęp do zmiennych można uzyskać wykonując polecenie: `> attach(Cars93)`. Do wartości określonej zmiennej odwołujemy się wówczas podając jej nazwę, np. `> Price`. Aby ponownie zablokować bezpośredni dostęp do zmiennych wystarczy napisać: `> detach(Cars93)`.

Zadanie 1 Pierwszy kontakt z danymi

a) Wczytaj dane Cars93 do przestrzeni roboczej R'a. Następnie przyjrzyj się danym wykorzystując dostępną w RStudio przeglądarkę (w tym celu można np. kliknąć na nazwę obiektu `Cars93` w zakładce Environment lub wpisać w konsoli R polecenie: `> View(Cars93)`).

b) Ile mamy cech (zmiennych) i ile obserwacji (przypadków)?

c) Które cechy (zmienne) są ilościowe (`numeric`), a które jakościowe (`factor`)?

d) Wyszukaj informacje o tych danych w systemie pomocy środowiska R.

e) Wypisz na ekranie wartości wybranych zmiennych:

- wykorzystując odwołania postaci `Cars93$nazwa.zmiennej`,
- wykorzystując komendę `attach()`.

f) Czy widoczne są jakieś nietypowe własności danych? Czy w danych występują brakujące wartości? (Uwaga: Brakujące wartości w R są standardowo oznaczane jako NA (Not Available)).

Zadanie 2 Informacja na temat pojedynczych cech (zmiennych)

a) Dla wybranej cechy ilościowej (np. `Price, Horsepower, Length, Width, MPG.city` itd.):

- wyznacz minimalną, maksymalną i średnią wartość tej zmiennej (można wykorzystać wbudowane R-funkcje: `min(), max(), mean()`),
- przeanalizuj częstości przyjmowania poszczególnych wartości przez tę zmienną (można wykorzystać np. funkcję `hist(zmienna, breaks=10)`, gdzie `breaks` - pożądana liczba przedziałów klasowych). Powtórz analizę dla różnej liczby przedziałów klasowych i zinterpretuj wyniki.

b) Dla wybranej cechy jakościowej (np. `Type, Manufacturer, Origin` itd.):

- przeanalizuj, ile różnych wartości i z jaką częstością przyjmuje ta zmienna (można wykorzystać np. funkcje `table()` i `prop.table()`),
- sporządź wykres przedstawiający częstość przyjmowania poszczególnych wartości (można wykorzystać np. funkcje `pie()` lub `barplot()`).

ZADANIE 3 **Odpowiedzi na proste pytania dotyczące danych**

a) Ile aut jest produkowanych w USA (Origin=='USA'), a ile importowanych (Origin=='non-USA')?

b) Ile jest samochodów sportowych z napędem na tylne koła (DriveTrain=='Rear')?
Jaka jest średnia cena (zm. Price) i średnia moc (zm. Horsepower) w grupie takich samochodów?

c) Ile wynosi średnia pojemność silnika (zm. EngineSize) aut produkowanych przez Chevroleta?

ZADANIE 4 **Wybór określonego podzbioru danych**

a) Wybierz podzbiór danych zawierający tylko informacje nt. aut klasy *compact* (Type=="Compact") o masie przekraczającej 3000 funtów. Uwaga: wybrany podzbiór ma zawierać wszystkie zmienne.

b) Wybierz podzbiór zawierający informacje nt. długości, szerokości i masy (zm. Length, Width, Weight) samochodów o cenie (zm. Price) nieprzekraczającej 15000$.

c) Wybierz podzbiór zawierający dane nt. 10-ciu samochodów o największym zużyciu paliwa, jeżeli weźmiemy pod uwagę jazdę miejską (zm. MPG.city)

d) Wybierz podzbiór danych zawierający wyłącznie zmienne ilościowe (typ `numeric`). *Wskazówka:* do sprawdzenia czy dana zmienna jest typu ilościowego można wykorzystać funkcję `is.numeric()`.

ZADANIE 5 **Proste przekształcenia zmiennych**

a) Na podstawie zmiennych `MPG.city` i `MPG.highway` (Uwaga: MPG = miles per gallon) utwórz nowe zmienne `Fuel.consump.city` i `Fuel.consump.highway`, które będą zawierały informację nt. zużycia paliwa wyrażoną w litrach na 100 km. *Wskazówka:* można przyjąć, że (w przybliżeniu) $1\ mila \approx 1.609\ km$ oraz $1\ galon \approx 3.785\ l$.

b) Na podstawie zmiennej ilościowej `Price` (średnia cena danego modelu samochodu) wyznacz zmienną jakościową `Price.category` (kategoria cenowa), która będzie zmienną typu `ordered factor` przyjmującą trzy możliwe wartości (poziomy): `low, medium, high`. *Wskazówka:* można wykorzystać wbudowaną funkcję `cut()`.

ZADANIE 6 **Analiza danych w podgrupach**

a) Porównaj średnie ceny samochodów poszczególnych typów: "Compact","Large","Midsize","Small", "Sporty", "Van". Czy różnice są istotne?

b) Porównaj zmienność (rozrzut) cen aut poszczególnych typów (np. wykorzystując funkcję `range()` – rozstęp, czyli wyznaczając różnicę między wartością maksymalną a minimalną). Dla której grupy zmienność cen jest największa?

c) Porównaj średnie ceny samochodów w grupach "USA" i "non-USA" (zmienna Origin).

d) Porównaj ceny samochodów z napędem na przednie koła z cenami samochodów o napędzie na tylne koła. Czy różnice są istotne?