Raport 2

Eksploracja danych

Michał Frąckowiak 275951 Matusz Goszczyński 275959

2025-04-30

Spis treści

1 Krótki opis zagadnienia **1**

2 Opis eksperymentów/analiz **2**

3 Opis zmiennych **2**
3.1 Obliczenie macierzy odmienności (dissimilarity matrix) 3
3.2 Diagram Sheparda do oceny jakości odwzorowania 4
3.3 Wizualizacja danych 5
3.4 Obserwacje nietypowe 8

4 Podsumowanie **8**

1 Krótki opis zagadnienia

W tym dokumencie przeprowadzimy redukcję wymiarowości danych Titanic przy użyciu metody skalowania wielowymiarowego (MDS). Będziemy analizować, jak poszczególne cechy pasażerów wpływają na ich rozmieszczenie w przestrzeni zredukowanej, ze szczególnym uwzględnieniem zmiennej `Survived`.

2 Opis eksperymentów/analiz

W niniejszym raporcie analizowane są dane dotyczące pasażerów statku Titanic, a głównym celem jest zastosowanie metody skalowania wielowymiarowego (MDS) do redukcji wymiarowości danych oraz oceny zależności pomiędzy zmiennymi opisującymi pasażerów a ich przeżyciem. Analiza rozpoczyna się od przygotowania danych oraz obliczenia macierzy odległości między obserwacjami. W tym celu wykorzystana zostaje funkcja daisy() z pakietu cluster, która umożliwia uwzględnienie zarówno zmiennych ilościowych, jak i jakościowych.

Na podstawie wyznaczonej macierzy odległości przeprowadzana jest analiza klasycznym MDS-em przy użyciu funkcji cmdscale(), która odwzorowuje dane w przestrzeni dwuwymiarowej. Dla celów wizualnych tworzony jest wykres punktowy, na którym obserwacje kolorowane są według zmiennej Survived, co umożliwia ocenę wizualnej separacji klas (pasażerów, którzy przeżyli i tych, którzy zginęli).

W eksperymentach porównywane są różne warianty analizy: obejmujące wszystkie zmienne jednocześnie, jedynie zmienne jakościowe, a także wyłącznie zmienne ilościowe. Pozwala to ocenić, które grupy cech najlepiej odwzorowują strukturę danych w przestrzeni dwuwymiarowej. Szczególną uwagę poświęca się jakości odwzorowania oraz interpretowalności uzyskanych wyników.

3 Opis zmiennych

	Lp	Nazwa_zmiennej	Opis_zmiennej	Typ
1	1	PassengerId	Unikalny identyfikator pasażera	integer
2	2	Survived	Czy pasażer przeżył (0 = Nie, 1 = Tak)	factor
3	3	Pclass	Klasa podróży (1 = 1. klasa, 2 = 2. klasa, 3 = 3. klasa)	factor
4	4	Name	Imię i nazwisko pasażera	character
5	5	Sex	Płeć pasażera (male, female)	factor
6	6	Age	Wiek pasażera	numeric
7	7	SibSp	Liczba rodzeństwa/małżonków na pokładzie	integer
8	8	Parch	Liczba rodziców/dzieci na pokładzie	integer
9	9	Ticket	Numer biletu	character
10	10	Fare	Opłata za bilet	numeric
11	11	Cabin	Numer kabiny (może być brak danych)	character
12	12	Embarked	Port zaokrętowania (C = Cherbourg, Q = Queenstown, S = Southampton)	factor

Tabela 1: Opis zmiennych w zbiorze Titanic

```r
# Usunięcie zmiennych identyfikujących
titanic_data <- titanic_train %>%
  dplyr::select(-PassengerId, -Name, -Ticket, -Cabin)

# Przekształcenie zmiennych na factor
titanic_data <- as.data.frame(lapply(titanic_data, function(x) {
  if(is.character(x)) {
    return(as.factor(x))
  } else {
    return(x)
  }
}))
```

Fragment kodu odpowiada za przygotowanie danych do dalszej analizy. W pierwszej kolejności usuwane są zmienne identyfikujące(3)., takie jak PassengerId, Name, Ticket oraz Cabin, ponieważ nie zawierają one informacji istotnych z punktu widzenia analizy struktury danych i mogą wprowadzać zakłócenia przy obliczaniu miar odległości. Następnie wszystkie zmienne typu tekstowego (character) są automatycznie przekształcane na zmienne typu czynnikowego (factor)(3)., co pozwala na ich właściwe uwzględnienie jako zmiennych kategorycznych podczas dalszego przetwarzania, w szczególności przy obliczaniu macierzy odległości

3.1 Obliczenie macierzy odmienności (dissimilarity matrix)

Tworzymy macierz odmienności dla danych, pomijając zmienną `Survived` zgodnie z wymaganiami:

```r
# Przygotowanie danych bez zmiennej Survived (ale zachowujemy ją do późniejszej analiz
titanic_features <- titanic_data %>% dplyr::select(-Survived)

# Obliczenie macierzy odmienności przy użyciu metryki Gowera
dissim_matrix <- daisy(titanic_features, metric = "gower")

# Podgląd fragmentu macierzy odmienności
as.matrix(dissim_matrix)[1:5, 1:5]
```

```
##           1         2         3         4          5
## 1 0.00000000 0.4751486 0.1680831 0.3218358 0.04141702
## 2 0.47514860 0.0000000 0.3427798 0.1533128 0.46944587
## 3 0.16808306 0.3427798 0.0000000 0.1894671 0.15904825
## 4 0.32183584 0.1533128 0.1894671 0.0000000 0.31613311
## 5 0.04141702 0.4694459 0.1590482 0.3161331 0.00000000
```

3.2 Diagram Sheparda do oceny jakości odwzorowania

```r
# Obliczenie odległości euklidesowych w przestrzeni MDS
mds_metric_2d <- cmdscale(dissim_matrix, k = 2, eig = TRUE)
mds_metric_2d_coords <- mds_metric_2d$points
mds_distances <- dist(mds_metric_2d_coords)

# Przygotowanie danych do wykresu
shepard_data <- data.frame(
  original_dist = as.vector(dissim_matrix),
  mds_dist = as.vector(mds_distances)
)
# Wykres Sheparda
ggplot(shepard_data, aes(x = original_dist, y = mds_dist)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", color = "red", se = FALSE) +
  labs(
    title = paste("Diagram Sheparda - Metryczne MDS"),
    x = "Odległości oryginalne",
    y = "Odległości w przestrzeni MDS"
  ) +
  theme_minimal()
```

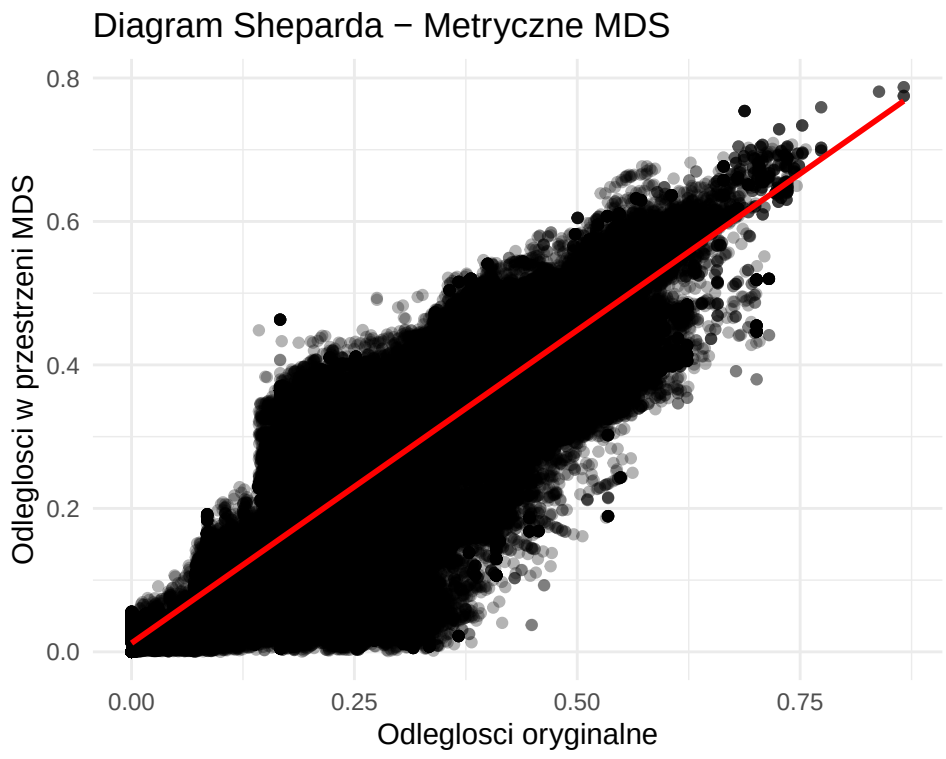

Diagram Sheparda(3.2) ilustruje jakość dopasowania odwzorowania wielowymiarowych danych

do przestrzeni dwuwymiarowej za pomocą metody MDS. Punkty rozmieszczone blisko linii y = x wskazują na dobre odwzorowanie – oznacza to, że struktura relacji między obiektami została zachowana.

```
# Obliczenie współczynnika korelacji jako miary jakości odwzorowania
correlation <- cor(shepard_data$original_dist, shepard_data$mds_dist)
cat(paste0("Współczynnik korelacji dla Metryczne MDS 2D: ", round(correlation, 4), "\n")
```

```
## Współczynnik korelacji dla Metryczne MDS 2D: 0.8718
```

Wysoki współczynnik korelacji(3.2) świadczy o dobrym odwzorowaniu odległości między punktami w przestrzeni dwuwymiarowej, co oznacza, że metryczne MDS skutecznie zachowuje relacje przestrzenne obecne w danych przed redukcją wymiarowości.

3.3 Wizualizacja danych

3.3.1 Wizualizacja MDS z kolorami według zmiennej Survived

```
# Dodanie nazw kolumn do wyników MDS (jeśli ich nie ma)
colnames(mds_metric_2d_coords) <- c("Dim1", "Dim2")

# Dodanie zmiennej Survived do wyników MDS

mds_metric_2d_with_survived <- data.frame(mds_metric_2d_coords,
                                          Survived = titanic_data$Survived)


# Wykresy 2D z kolorami według Survived
ggplot(mds_metric_2d_with_survived, aes(x = Dim1, y = Dim2, color = factor(Survived))) +
  geom_point(alpha = 1) +
  scale_color_manual(values = c("0" = "red", "1" = "blue"),
                     labels = c("0" = "No", "1" = "Yes")) +
  labs(title = "Metryczne MDS (2D) z kolorami według Survived", color = "Przeżył") +
  theme_minimal()
```

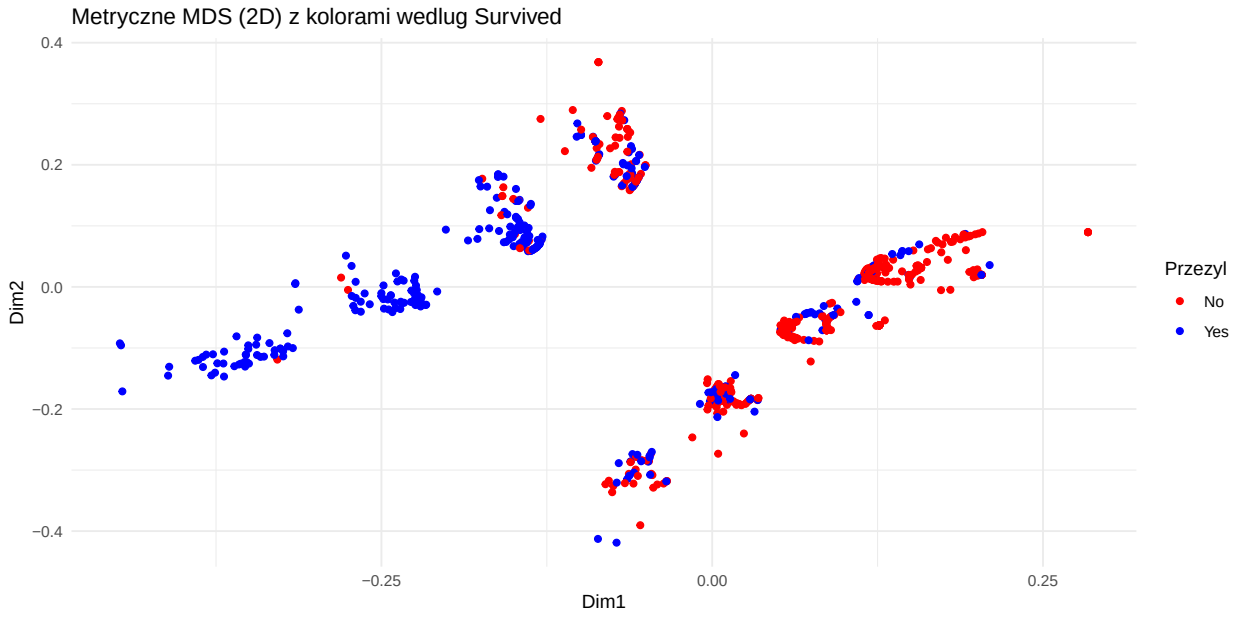

Osoby, które przeżyły katastrofę (kolor niebieski), wydają się częściowo grupować w określonych obszarach przestrzeni MDS, co sugeruje, że cechy wykorzystane do analizy (Sex, Class, Age) mają związek z przeżywalnością(3.3.1). Nie jest to jednak całkowite rozdzielenie grup, co wskazuje, że same te cechy nie są w pełni determinujące przeżywalność.

3.3.2 Wizualizacja MDS z kolorami według zmiennych Sex i Pclass

```
# Dodanie zmiennych Sex i Pclass do wyników MDS
mds_metric_2d_with_features <- cbind(mds_metric_2d_coords,
                                     Sex = titanic_data$Sex,
                                     Pclass = titanic_data$Pclass)

# Wykres 2D z kolorami według Sex
ggplot(mds_metric_2d_with_features, aes(x = Dim1, y = Dim2, color = factor(Sex))) +
  geom_point(alpha = 0.7) +
  labs(title = "Metryczne MDS (2D) z kolorami według Sex", color = "Płeć") +
  geom_text(aes(label = Sex)) +
  theme_minimal()
```

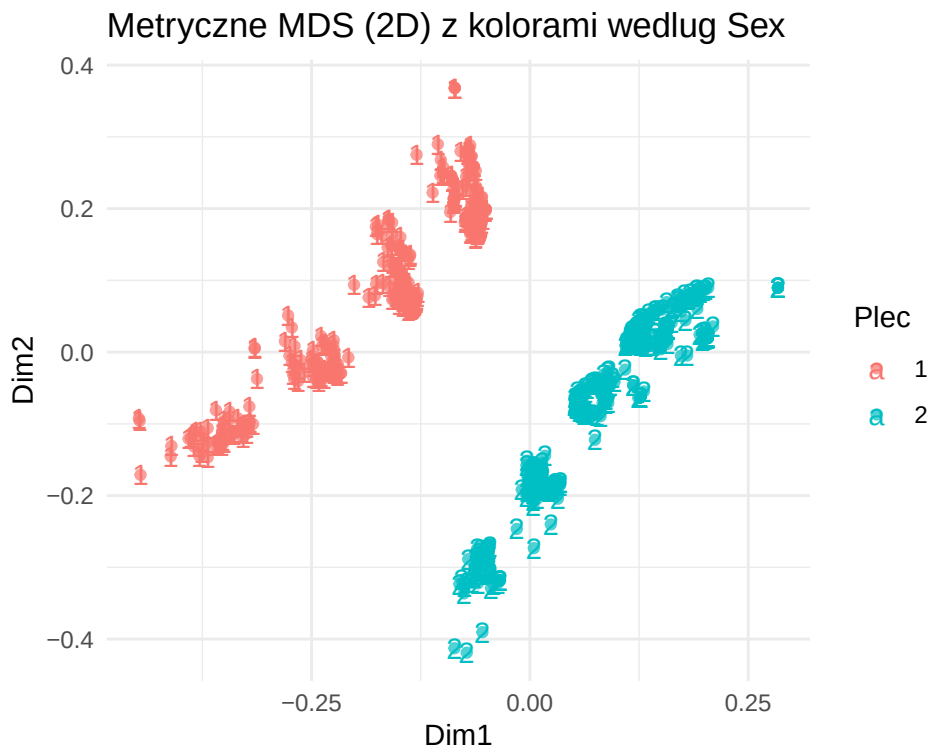

Pasażerowie płci męskiej i żeńskiej tworzą dość wyraźne, oddzielne skupiska, co sugeruje, że płeć jest istotnym czynnikiem różnicującym(3.3.2).

```
# Wykres 2D z kolorami według Pclass
ggplot(mds_metric_2d_with_features, aes(x = Dim1, y = Dim2, color = factor(Pclass))) +
  geom_point(alpha = 0.7) +
  scale_color_brewer(palette = "Set1") +
  labs(title = "Metryczne MDS (2D) z kolorami według Pclass", color = "Klasa") +
  theme_minimal()
```

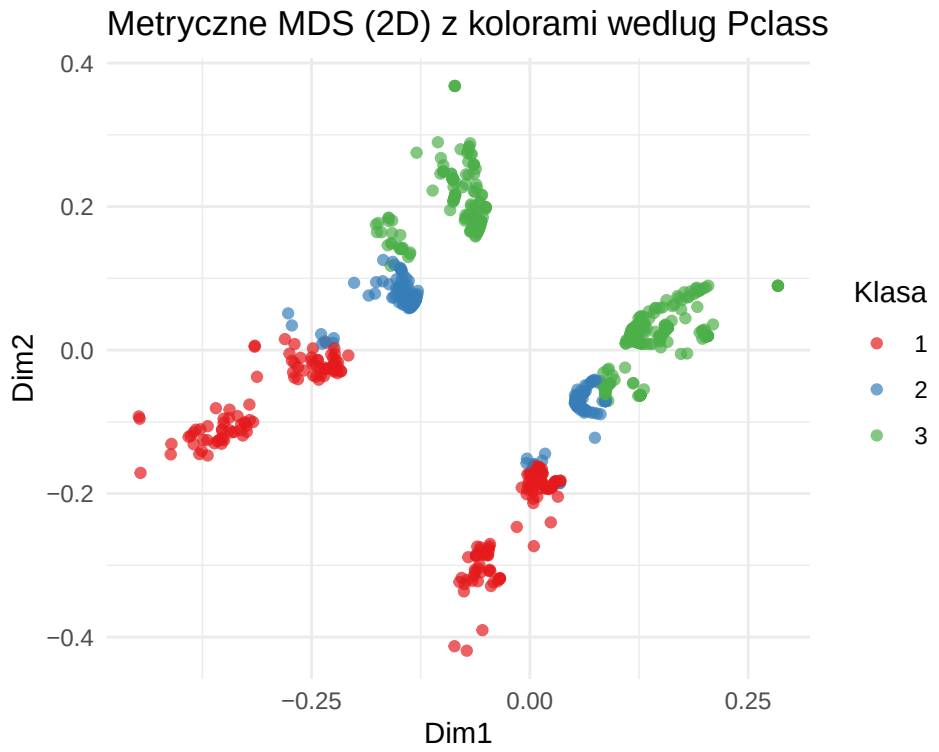

Obserwujemy tendencję do formowania się odrębnych skupisk punktów odpowiadających poszczególnym klasom. Mimo pewnego stopnia nakładania się obserwacji, szczególnie pomiędzy klasą 2 i 3, ogólna struktura przestrzenna sugeruje, że klasa podróży ma wpływ na rozmieszczenie danych(3.3.2).

3.4 Obserwacje nietypowe

Na wykresach widoczne są pojedyncze punkty oddalone od głównych skupisk, co może wskazywać na obserwacje nietypowe. Te nietypowe przypadki mogą reprezentować pasażerów, którzy nie pasują do ogólnych wzorców związanych z ich grupą demograficzną, np.: - Mężczyźni z pierwszej klasy, którzy przeżyli (mimo że większość mężczyzn nie przeżyła) - Kobiety z trzeciej klasy, które nie przeżyły (mimo że większość kobiet przeżyła)

4 Podsumowanie

Analiza MDS potwierdza znaną historyczną prawidłowość, że płeć i klasa podróży były kluczowymi czynnikami wpływającymi na przeżywalność podczas katastrofy Titanica.
- Kobiety z wyższych klas miały największe szanse na przeżycie, co widać w grupowaniu na wykresach(3.3.2)(3.3.2).
- Mężczyźni z niższych klas mieli najmniejsze szanse na przeżycie(3.3.2)(3.3.2).
- Istnieją wyjątki od tych reguł, widoczne jako punkty oddalone od głównych skupisk(3.2).