Raport 2

Eksploracja danych

Michał Frąckowiak 275951 Matusz Goszczyński 275959

2025-06-24

Spis treści

1 Krótki opis zagadnienia **1**

2 Opis eksperymentów/analiz **2**

3 Opis zmiennych **2**

4 Wyniki **3**

5 Podsumowanie **17**
5.1 Najlepszy algorytm: 17
5.2 Optymalna liczba klastrów: 17

1 Krótki opis zagadnienia

naliza skupień (ang. clustering) to metoda eksploracji danych mająca na celu podział zbioru obserwacji na grupy (klastry), w których elementy są do siebie podobne, a różne grupy są od siebie wyraźnie odróżnialne. W pracy zastosowano metody grupowania hierarchicznego (np. AGNES) oraz metody podziałowe, które wizualizowano przy pomocy techniki redukcji wymiaru — wielowymiarowego skalowania (MDS). MDS służy do przekształcenia danych do przestrzeni dwuwymiarowej, co ułatwia interpretację i wizualizację skupień. Analiza skupień umożliwia wykrycie naturalnej struktury w danych bez uprzedniej wiedzy o etykietach klas.

2 Opis eksperymentów/analiz

Przygotowano dane: usunięto etykiety klas oraz, w razie potrzeby, wybrano losowy podzbiór 200 obserwacji i dokonano standaryzacji. Zastosowano metodę hierarchiczną AGNES z różnymi metodami łączenia, a podziały na klastry uzyskano przez cięcie dendrogramu na liczbę odpowiadającą rzeczywistym klasom.

Wyniki grupowania zwizualizowano za pomocą wielowymiarowego skalowania (MDS), gdzie kolory oznaczały klastry, a symbole rzeczywiste klasy. Jakość grupowania oceniono przy pomocy indeksu silhouette oraz miar zgodności z rzeczywistym podziałem, co pozwoliło wybrać optymalną liczbę klastrów i lepszą metodę grupowania. Na końcu przeprowadzono analizę charakterystyk poszczególnych skupień.

3 Opis zmiennych

Tabela 1: Opis zmiennych w zbiorze danych Vehicle

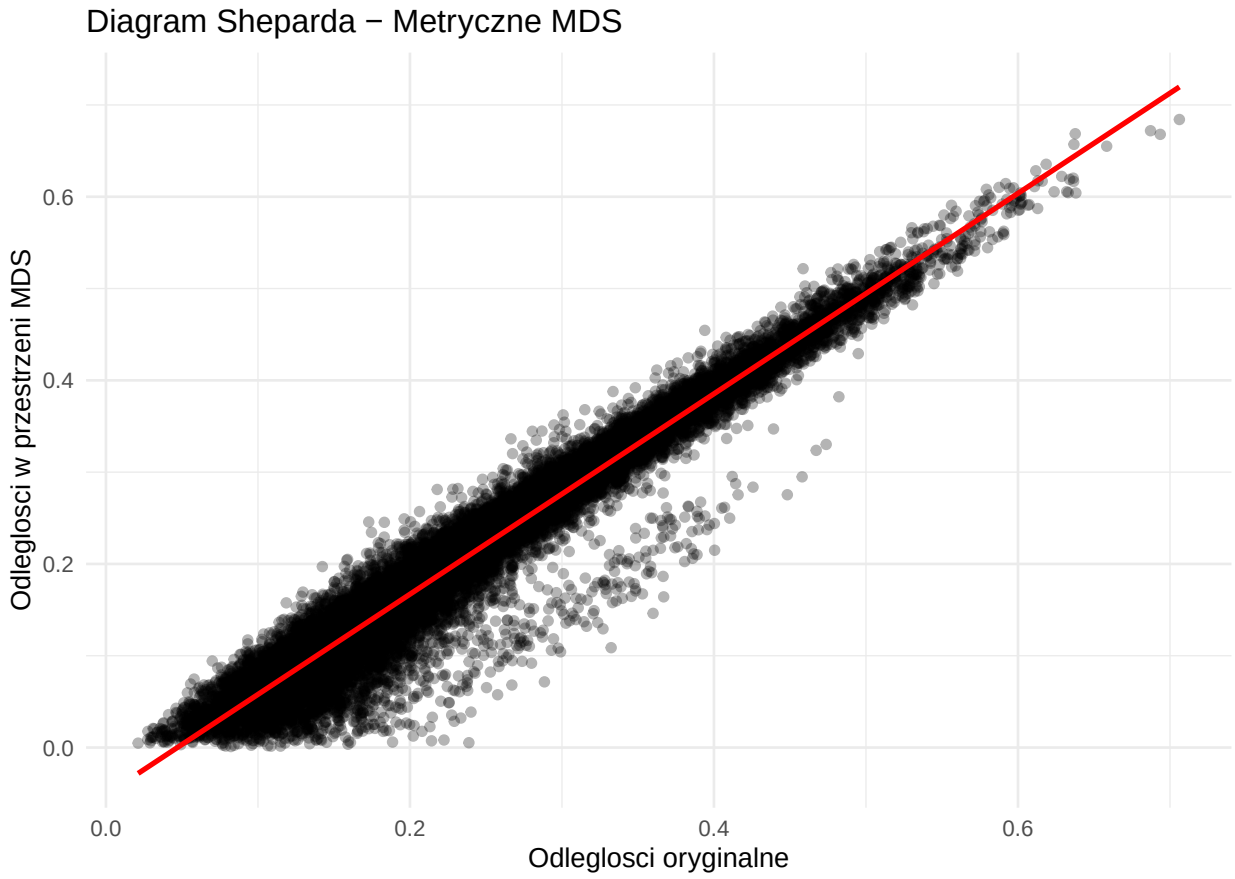
Nazwa.zmiennej	Typ.zmiennej	Opis
Comp	numeryczna (ciągła)	Kompaktowość - miara zwartości kształtu pojazdu
Circ	numeryczna (ciągła)	Kołowość - stopień podobieństwa kształtu do koła
D.Circ	numeryczna (ciągła)	Odległość kołowości - miara odchylenia od idealnego koła
Rad.Ra	numeryczna (ciągła)	Stosunek promieni - relacja między promieniami w różnych kierunkach
Pr.Axis.Ra	numeryczna (ciągła)	Stosunek osi głównych - proporcja między głównymi osiami elipsy
Max.L.Ra	numeryczna (ciągła)	Stosunek długości do szerokości - maksymalna długość do maksymalnej szeroko
Scat.Ra	numeryczna (ciągła)	Stosunek rozproszenia - miara rozproszenia punktów kształtu
Elong	numeryczna (ciągła)	Wydłużenie - miara tego, jak bardzo kształt jest wydłużony
Pr.Axis.Rect	numeryczna (ciągła)	Prostokątność osi głównych - jak bardzo kształt przypomina prostokąt względe
Max.L.Rect	numeryczna (ciągła)	Prostokątność długości i szerokości - prostokątność względem wymiarów maksy
Sc.Var.Maxis	numeryczna (ciągła)	Wariancja skalowana dla osi głównej - znormalizowana wariancja wzdłuż osi gł
Sc.Var.minor	numeryczna (ciągła)	Wariancja skalowana dla osi pobocznej - znormalizowana wariancja wzdłuż osi p
Ra.Gyr	numeryczna (ciągła)	Promień żyracji - miara koncentracji masy kształtu
Skew.Maxis	numeryczna (ciągła)	Skośność wzdłuż osi głównej - asymetria rozkładu punktów wzdłuż osi głównej
Skew.minor	numeryczna (ciągła)	Skośność wzdłuż osi pobocznej - asymetria rozkładu punktów wzdłuż osi poboc
Kurt.Maxis	numeryczna (ciągła)	Kurtoza wzdłuż osi głównej - spłaszczenie rozkładu punktów wzdłuż osi głównej
Kurt.minor	numeryczna (ciągła)	Kurtoza wzdłuż osi pobocznej - spłaszczenie rozkładu punktów wzdłuż osi pobo
Holl.Ra	numeryczna (ciągła)	Stosunek pustych obszarów - proporcja przestrzeni pustej wewnątrz kształtu
Class	kategoryczna (factor)	Typ pojazdu: bus (autobus), saab, van (furgonetka), opel

4 Wyniki

```
selected_indices <- sample(1:nrow(Vehicle), size = 200, replace = FALSE)
Vehicle <- Vehicle[selected_indices, ]
Vehicle_train <- Vehicle %>% dplyr::select(-Class)
```

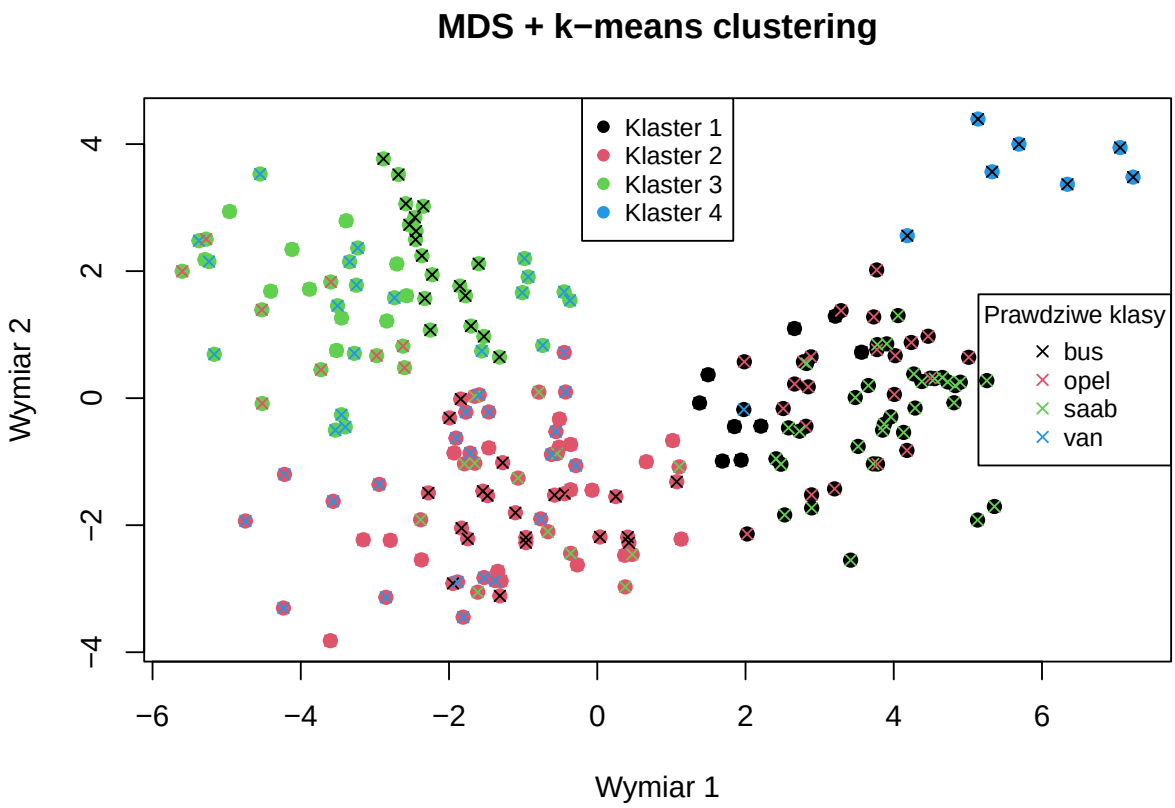
Zbiór Vehicle zawiera 18 zmiennych geometrycznych, które mogą mieć bardzo różne zakresy wartości. Standaryzacja sprawia, że zmienne stają się porównywalne, szczególnie gdy są mierzone w różnych skalach

```
Vehicle_standardized <- scale(Vehicle_train)
```



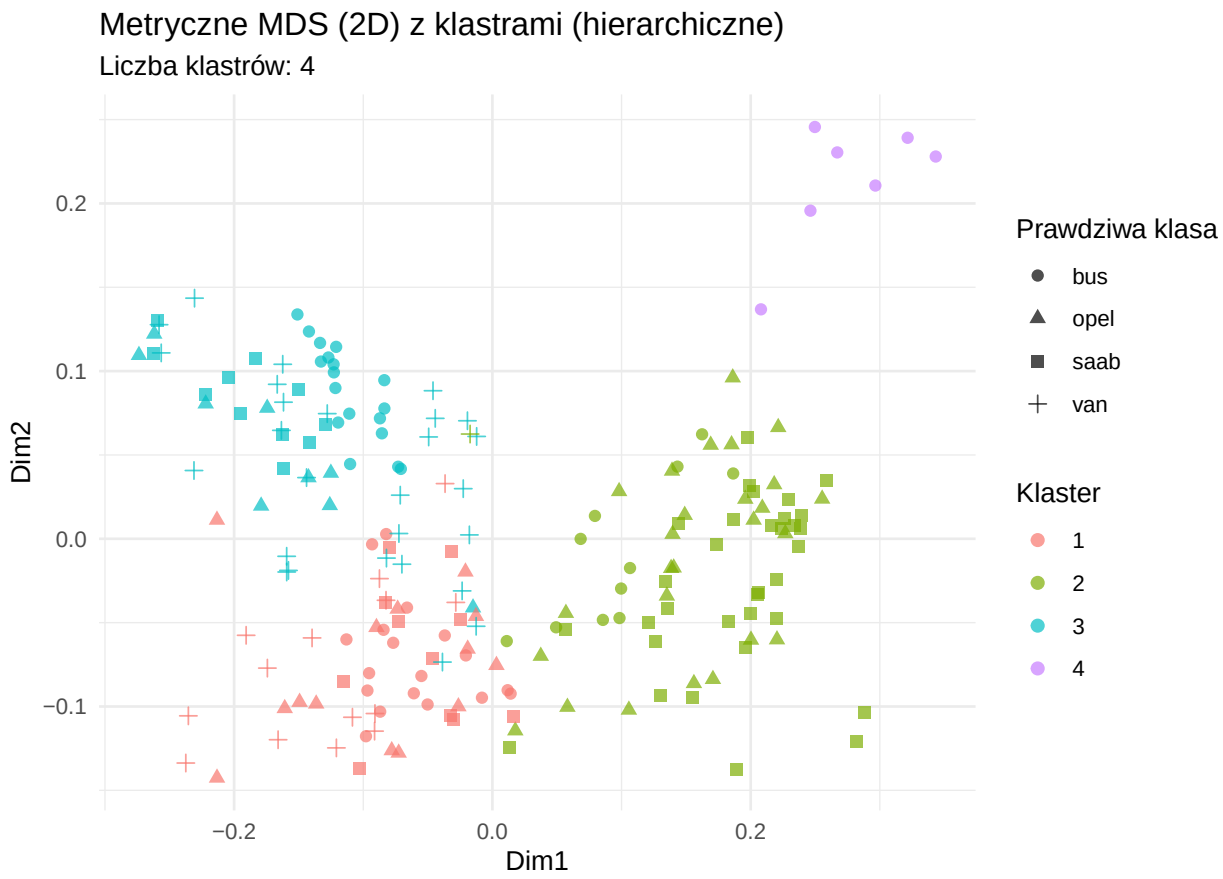
Rysunek 1: Diagram Sheparda

Rozmieszczenie punktów na diagramie Sheparda (1), które układają się blisko linii trendu, wskazuje na silną korelację między pierwotnymi odległościami w danych a odległościami w zredukowanej, dwuwymiarowej przestrzeni. Oznacza to, że redukcja wymiaru za pomocą MDS dobrze zachowała oryginalną strukturę odległości między obiektami.



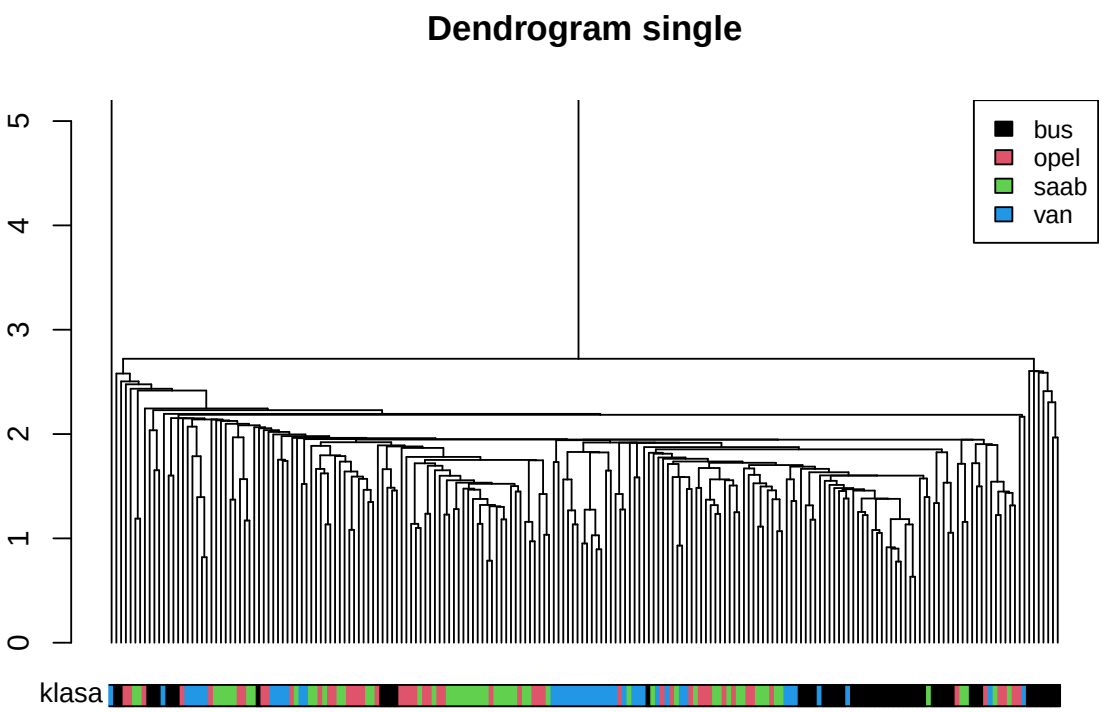
Rysunek 2: MDS z klastrami k-means

Wizualizacja grupowania k-means na płaszczyźnie MDS (2) pokazuje, że skupienia (oznaczone kolorami) częściowo pokrywają się z rzeczywistymi klasami pojazdów (oznaczonymi symbolami). Można zauważyć, że niektóre klasy są trudne do rozróżnienia i trafiają do tych samych klastrów, podczas gdy inne tworzą bardziej jednorodne grupy.



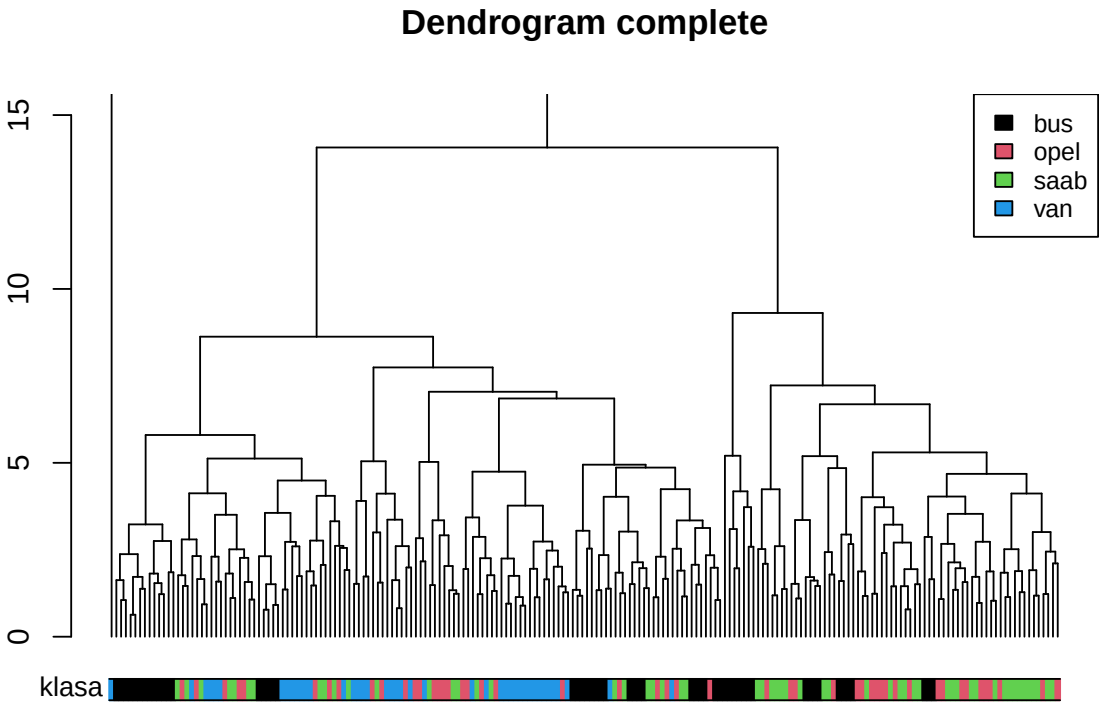
Rysunek 3: MDS z klastrami hierarchicznymi

Podział uzyskany metodą hierarchiczną (3) wizualnie prezentuje minimalnie lepsze oddzielenie grup. Klastry (kolory) wydają się bardziej spójne z rzeczywistymi klasami (kształty), co sugeruje, że ta metoda mogła lepiej uchwycić strukturę danych w tym przypadku.



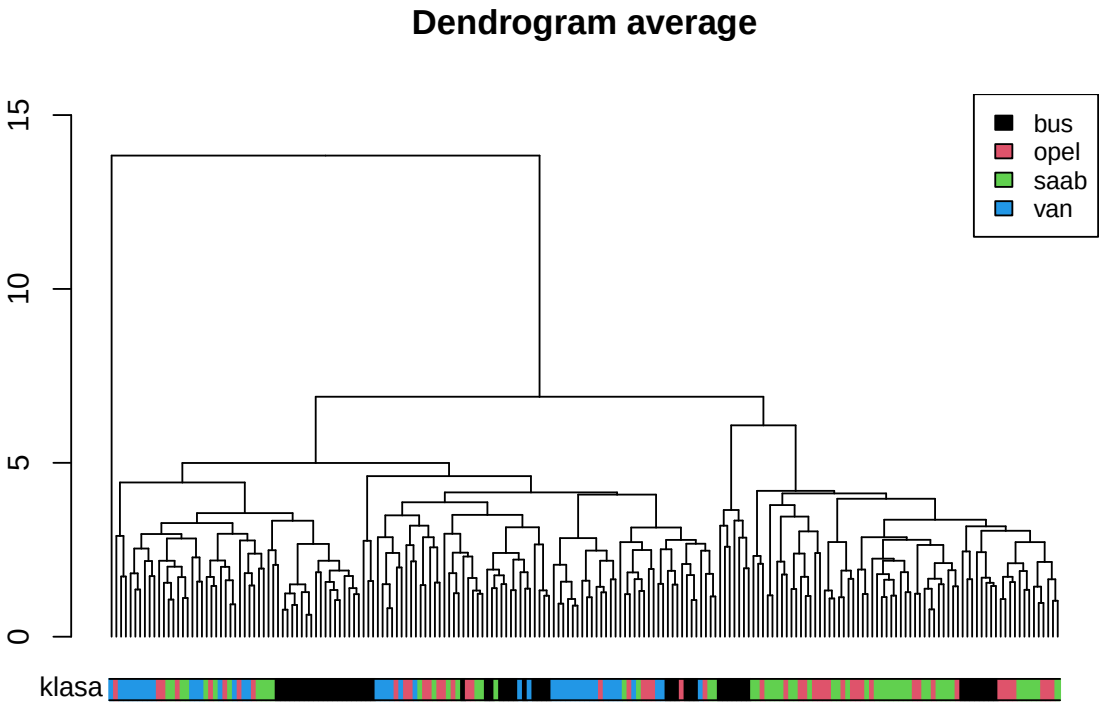
Rysunek 4: Dendrogram metoda single

Denagram(4) ma bardzo "płaską" strukturę z większością połączeń występujących na poziomach 1-2, a następnie jednym dramatycznym skokiem do poziomu około 5. charakteryzuje się "łańcuchowaniem", gdzie pojedyncze obserwacje są dołączane do istniejących, dużych skupień. Skutkuje to kliloma stosunkowo zwartymi grupami, jednakże większość danych jest wymieszana. Trudno jest zidentyfikować naturalne, dobrze oddzielone klastry.



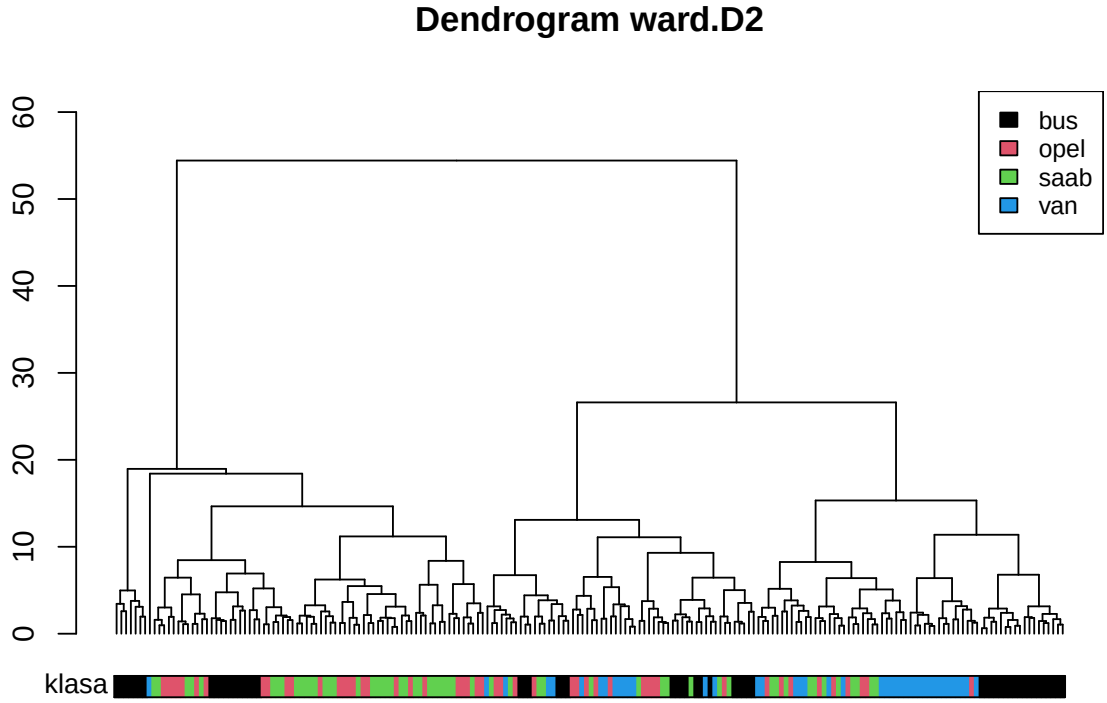
Rysunek 5: Dendrogram metoda complete

Dendrogram dla metody pełnego wiązania (5) tworzy bardziej zwarte i wyraźnie oddzielone klastry. Kolorowe paski wskazują, że obiekty należące do tej samej prawdziwej klasy częściej grupują się w tych samych gałęziach dendrogramu, co świadczy o lepszym dopasowaniu niż w metodzie pojedynczego wiązania.



Rysunek 6: Dendrogram metoda average

Struktura jest znacznie bardziej interpretowalna niż w przypadku single linkage, z wyraźnymi grupami zamiast jednego długiego łańcucha.(6), wykazuje bardziej równomierne rozłożenie skupień . Niektóre marki występują częściej w określonych częściach dendrogramu, co sugeruje, że metoda skutecznie identyfikuje podobieństwa między pojazdami.



Dendrogram(**??**) pokazuje wyraźne podziały na kilka głównych grup przy różnych poziomach odległości. Najważniejszy podział występuje na wysokości około 55, dzieląc dane na dwie główne gałęzie. Struktura dendrogramu sugeruje, że niektóre pojazdy mają podobne charakterystyki, szczególnie często mieszaja sie saab i opel.Obserwując kolorowe paski na dole, można zauważyć pewne wzorce w grupowaniu różnych marek, co sugeruje, że metoda najskuteczniej identyfikuje podobieństwa między pojazdami.

Rysunek 7: Dendrogram metoda ward.D2

```
for(k in K_range) {
  # k-means na współrzędnych MDS
  kmeans_mds <- kmeans(mds_coords, centers = k, nstart = 25)
  kmeans_clusters <- kmeans_mds$cluster

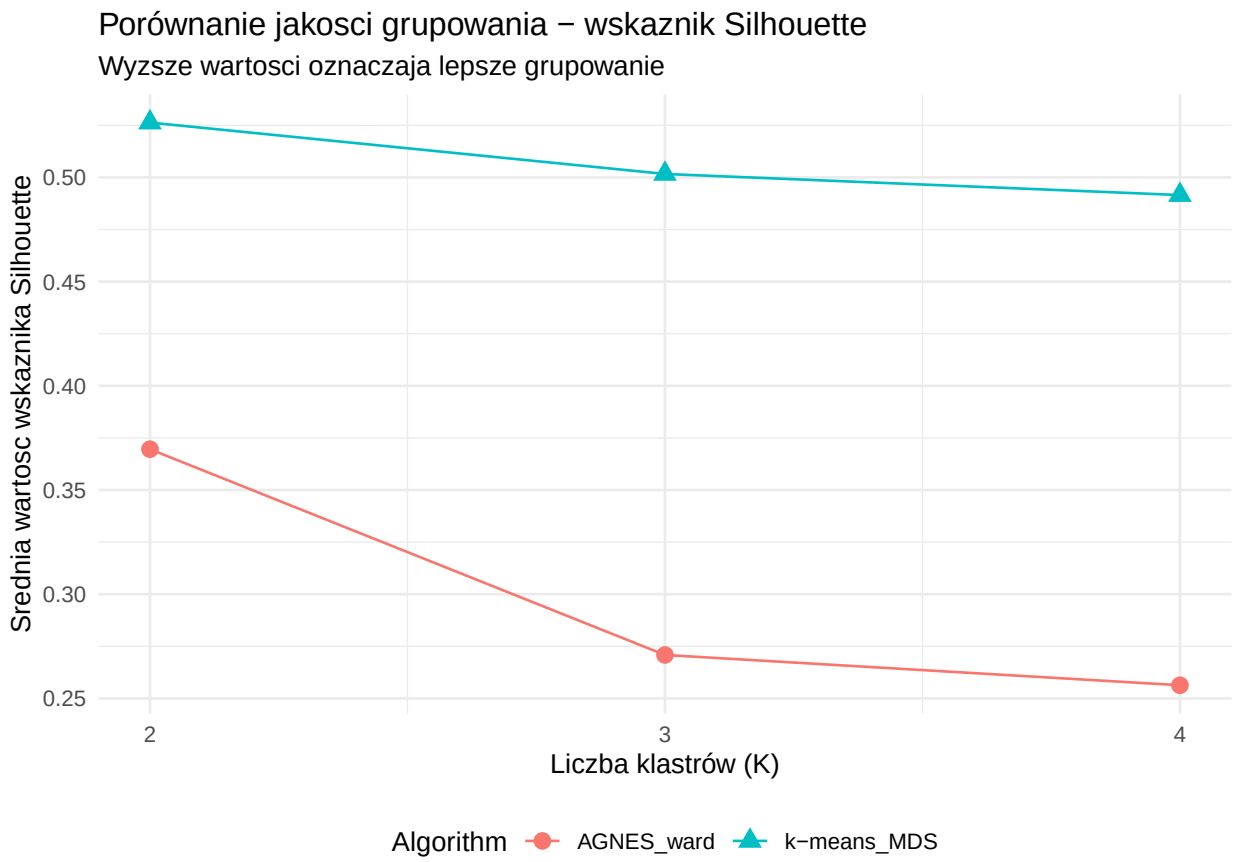
  # Silhouette dla k-means na MDS
  if(k > 1 && k < nrow(mds_coords)) {
    sil_kmeans <- silhouette(kmeans_clusters, dist(mds_coords))
    avg_sil_kmeans <- mean(sil_kmeans[, 3])
    results_internal[results_internal$K == k & results_internal$Algorithm == "k-means_MDS
  }
```

```
  # Accuracy dla k-means - sprawdzenie czy k odpowiada liczbie prawdziwych klas
  if(k <= length(unique(true_labels))) {
    confusion_matrix <- table(kmeans_clusters, true_labels)
    if(nrow(confusion_matrix) > 0 && ncol(confusion_matrix) > 0) {
      matched_clusters <- apply(confusion_matrix, 1, which.max)
      matched_labels <- matched_clusters[kmeans_clusters]
      accuracy_kmeans <- sum(matched_labels == true_labels) / length(true_labels)
      results_external[results_external$K == k & results_external$Algorithm == "k-means_M
    }
  }

  # AGNES
  agnes_clusters <- cutree(hclust_ward, k = k)

  # Silhouette dla AGNES
  if(k > 1 && k < length(agnes_clusters)) {
    sil_agnes <- silhouette(agnes_clusters, dissim_matrix)
    avg_sil_agnes <- mean(sil_agnes[, 3])
    results_internal[results_internal$K == k & results_internal$Algorithm == "AGNES_ward"
  }

  # Accuracy dla AGNES
  if(k <= length(unique(true_labels))) {
    confusion_matrix_agnes <- table(agnes_clusters, true_labels)
    if(nrow(confusion_matrix_agnes) > 0 && ncol(confusion_matrix_agnes) > 0) {
      matched_clusters_agnes <- apply(confusion_matrix_agnes, 1, which.max)
      matched_labels_agnes <- matched_clusters_agnes[agnes_clusters]
      accuracy_agnes <- sum(matched_labels_agnes == true_labels) / length(true_labels)
      results_external[results_external$K == k & results_external$Algorithm == "AGNES_war
    }
  }
}
```

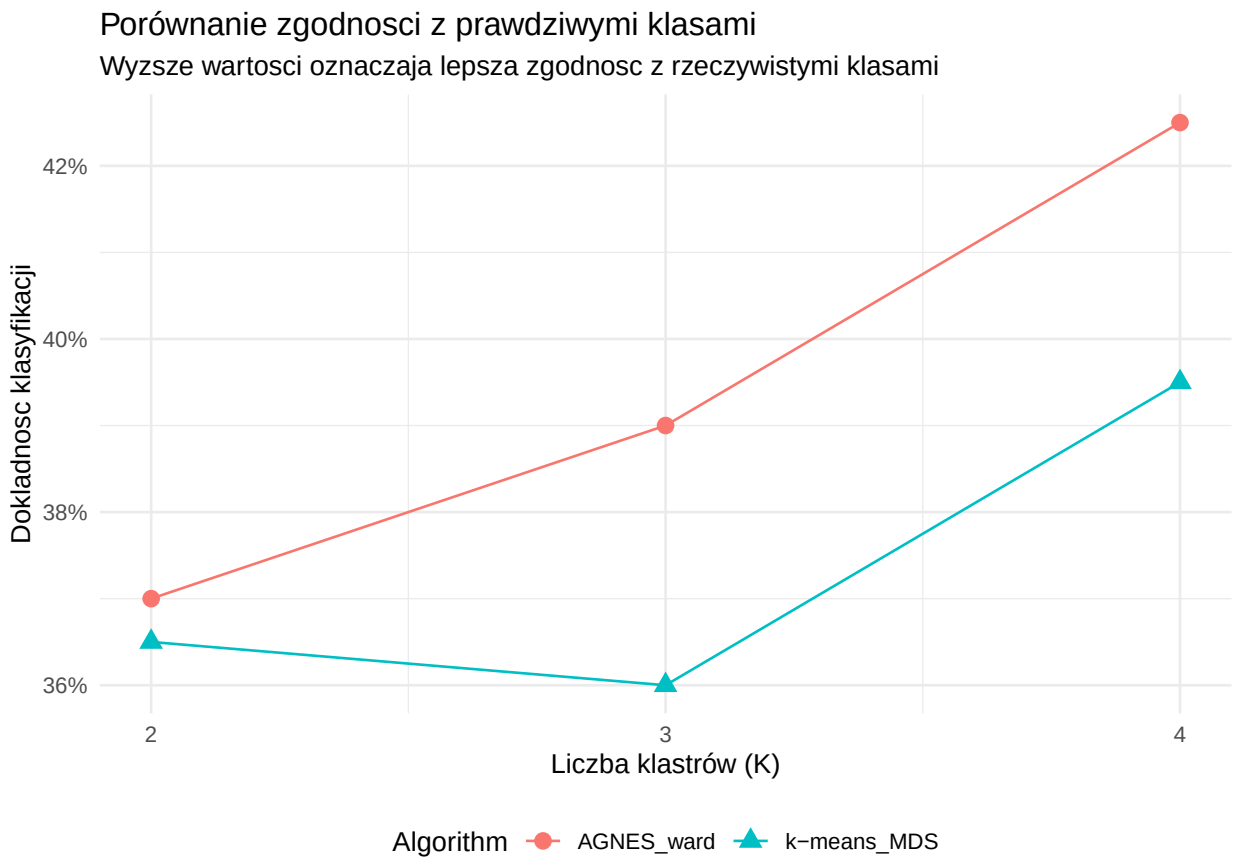


k-means na MDS:

Najwyższa wartość przy K=2 (˜0.55) - sugeruje naturalny podział danych na dwie główne grupy Stabilizacja na poziomie ˜0.4 dla K>4 - wartości powyżej 0.4 wskazują na "rozsądną" strukturę klastrów

AGNES ward:

Najwyższa wartość przy K=2 (˜0.4) - niższa niż k-means, ale wciąż akceptowalna



AGNES ward:

Ciągły wzrost: K=2 (37%) → K=3 (39%) → K=4 (43%) Najlepsza accuracy przy K=4 (prawdziwa liczba klas)

k-means na MDS:

Spadek: K=2 (36.5%) → K=3 (36%) → wzrost do K=4 (39.5%) Poprawa przy K=4, ale wciąż niższa niż AGNES

- Wysoka wartość przy K=2 w obu algorytmach sugeruje, że dane mają naturalną strukturę dwuklasową
- Spadek jakości przy wyższych K może oznaczać wymuszanie nadmiernego podziału
- Konflikt z liczbą prawdziwych klas (4) wskazuje na złożoność struktury danych Vehicle

Możemy postawić teze że K = 2 jest lepszym wyborem ale sprwawdzmy dalej...

```
## === NAJLEPSZE WYNIKI ===

##   K   Algorithm Silhouette
## 1 2 k-means_MDS  0.5263202

##    K  Algorithm Accuracy
## 10 4 AGNES_ward    0.425

##
```

```
## === WYNIKI DLA K=4 (prawdziwa liczba klas) ===

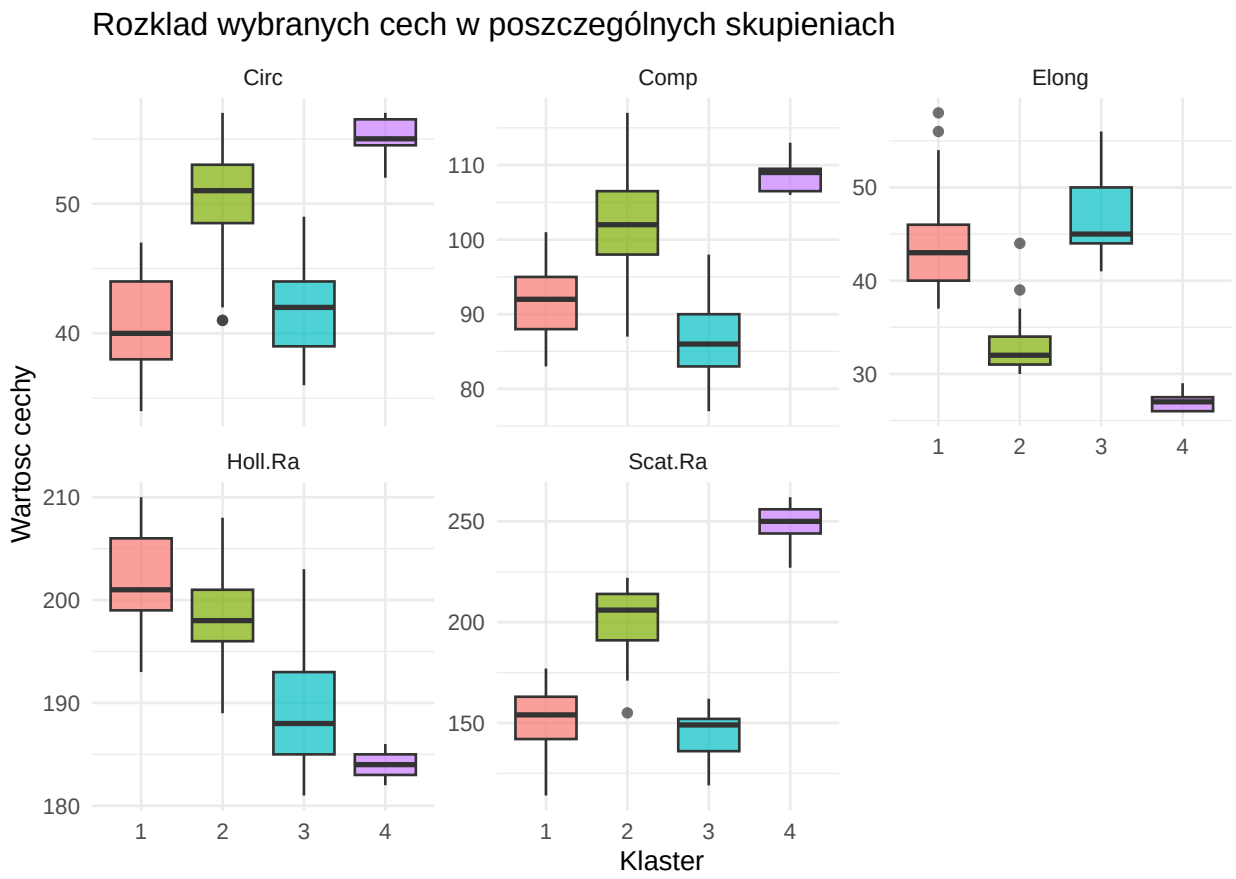
## [1] "Wskaźniki wewnętrzne (K=4):"

##    K   Algorithm Silhouette
## 3  4 k-means_MDS  0.4915352
## 10 4  AGNES_ward  0.2563176

## [1] "Wskaźniki zewnętrzne (K=4):"

##    K   Algorithm Accuracy
## 3  4 k-means_MDS    0.395
## 10 4  AGNES_ward    0.425

## # A tibble: 4 x 19
##   Cluster  Comp  Circ D.Circ Rad.Ra Pr.Axis.Ra Max.L.Ra Scat.Ra Elong
##   <fct>   <dbl> <dbl>  <dbl>  <dbl>      <dbl>    <dbl>   <dbl> <dbl>
## 1 1        91.8  40.8   75.3   168.       63.2     7.23    152.  43.6
## 2 2       102.   50.6   98.2   203.       64.1    10.0     202.  32.8
## 3 3        86.9  41.8   70.2   137.       58.2     7.38    144.  47.0
## 4 4       109.   55.1  103.    195.       57       5.57    248.  27
## # i 10 more variables: Pr.Axis.Rect <dbl>, Max.L.Rect <dbl>,
## #   Sc.Var.Maxis <dbl>, Sc.Var.maxis <dbl>, Ra.Gyr <dbl>, Skew.Maxis <dbl>,
## #   Skew.maxis <dbl>, Kurt.maxis <dbl>, Kurt.Maxis <dbl>, Holl.Ra <dbl>
```



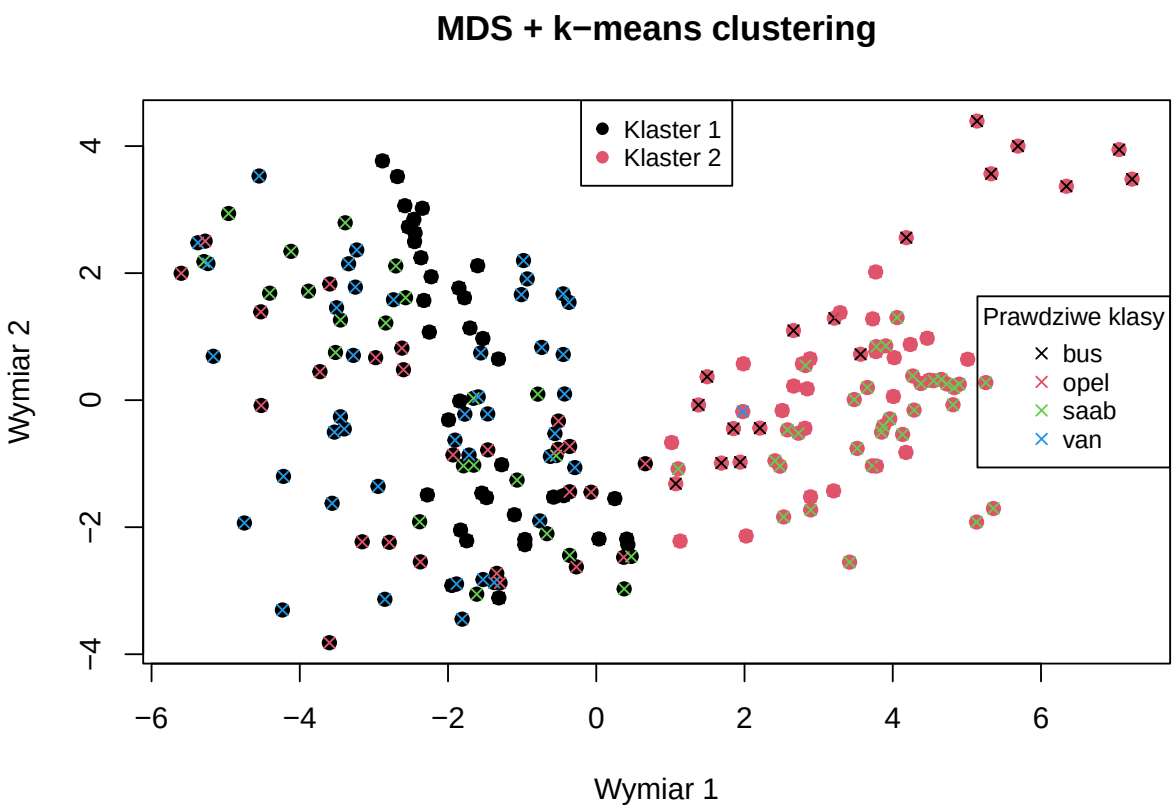
Rysunek 8: boxplot z podziałem na 4 skupienia

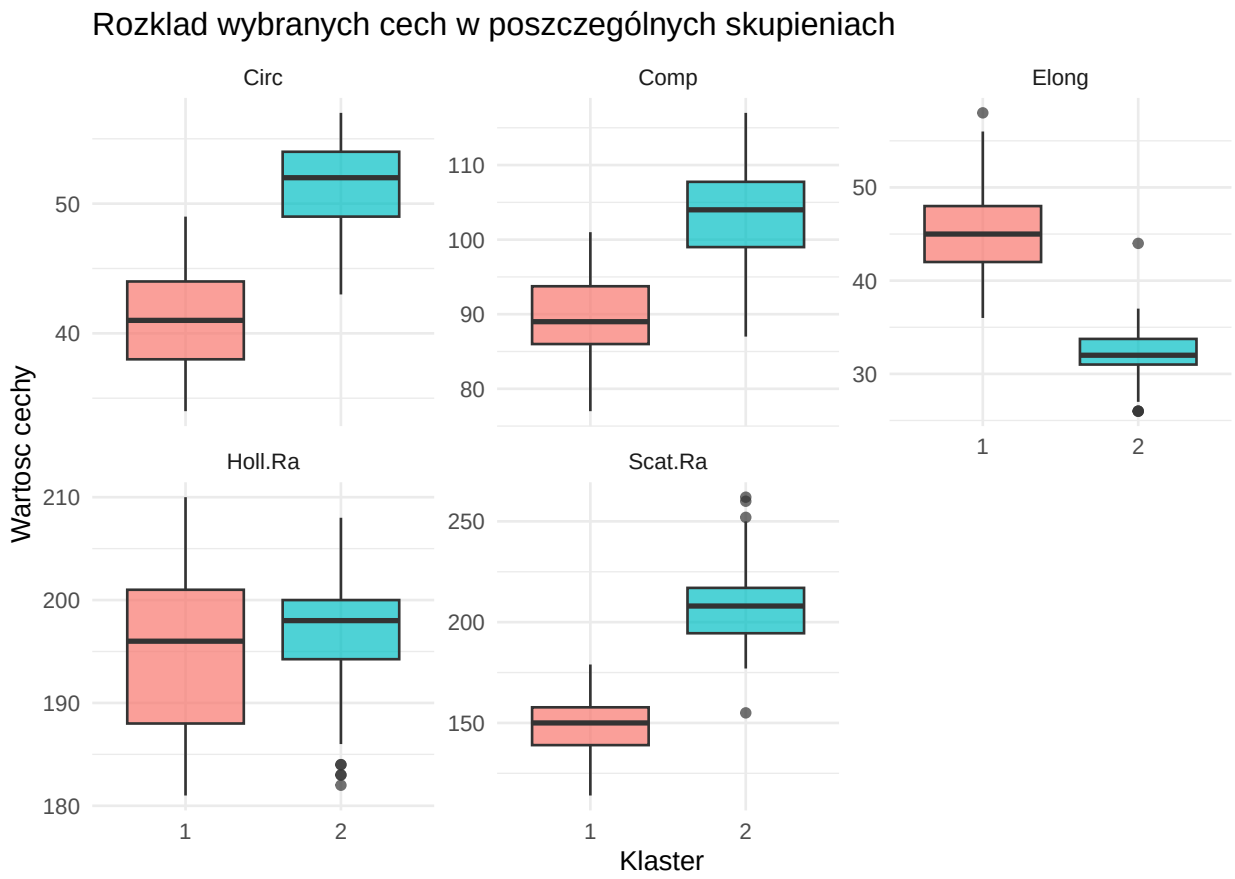
Klaster 1 To skupienie zawiera obiekty o nieregularnych kształtach z dużą liczbą lub rozmiarem wewnętrznych struktur (dziur/otworów).

Klaster 2 Obiekty zwarte, regularne, o kształtach zbliżonych do koła, ale z dużym rozproszeniem wewnętrznym.

Klaster 3 Obiekty wydłużone, mało zwarte, z niewielką liczbą wewnętrznych struktur i małym rozproszeniem.

Klaster 4 Obiekty o bardzo regularnych, zwartych kształtach z minimalną liczbą wewnętrznych struktur, ale z ekstremalnie wysokim rozproszeniem wewnętrznym.


MDS + k−means clustering
Klaster 1
Klaster 2
Prawdziwe klasy
bus
opel
saab
van
Wymiar 2
Wymiar 1
−6
−4
−2
0
2
4
6
−4
−2
0
2
4



Rysunek 9: boxplot z podziałem na 2 skupienia

Analizując wykres pudełkowy dla klastrowania na 2 skupienia(9), można stwierdzić, że to nowe klastrowanie jest gorsze w porównaniu do wcześniejszej analizy z 4 klastrami(8). Grupy są szerokie i zawierają obiekty o bardzo zróżnicowanych charakterystykach

5 Podsumowanie

5.1 Najlepszy algorytm:

AGNES ward jest lepszym wyborem:

Najwyższa accuracy (43% vs 39.5% dla k-means) Konsystentny wzrost jakości z rosnącą liczbą klastrów *Lepsze dopasowanie do rzeczywistej struktury danych

5.2 Optymalna liczba klastrów:

K=4 jest optymalnym wyborem