Krótki opis zagadnienia

Naszym celem jest eksploracja danych dotyczących klientów firmy telekomunikacyjnej oraz analiza czynników wpływających na ich rezygnację z usług. W szczególności:

- Jakie cechy klientów wpływają na decyzję o rezygnacji?
- Jakie są główne różnice między klientami, którzy pozostają, a tymi, którzy odchodzą?
- Czy można przewidzieć odejście klienta na podstawie dostępnych danych?

Opis eksperymentów/analiz

- *Dane*: Zbiór *WA_Fn-UseC_-Telco-Customer-Churn.csv* (źródło: Kaggle).
- *Eksperymenty*:
  - Wczytanie i wstępna eksploracja danych.
  - Analiza opisowa zmiennych.
  - Podział klientów na grupy (Churn = "Yes" vs Churn = "No").
  - Wizualizacja rozkładu cech i zależności między zmiennymi.
- *Narzędzia*:
  - Wykresy (histogramy, pudełkowe, słupkowe, wykresy rozrzutu).
  - Wskaźniki statystyczne (średnia, mediana, odchylenie standardowe).

Wczytanie danych

Opis zmiennych

Table 1: Tabela: Opis zmiennych w zbiorze Telco Customer Churn

Lp	Nazwa_zmiennej	Opis_zmiennej	Typ
1	customerID	Unikalny identyfikator klienta	character
2	gender	Płeć klienta (Male, Female)	factor
3	SeniorCitizen	Czy klient jest seniorem (0 = Nie, 1 = Tak)	numeric
4	Partner	Czy klient ma partnera (Yes, No)	factor
5	Dependents	Czy klient ma osoby na utrzymaniu (Yes, No)	factor
6	tenure	Liczba miesięcy bycia klientem	numeric
7	PhoneService	Czy klient ma usługę telefoniczną (Yes, No)	factor
8	MultipleLines	Czy klient ma wiele linii telefonicznych	factor
9	InternetService	Rodzaj internetu (DSL, Fiber optic, No)	factor
10	OnlineSecurity	Czy klient ma usługę zabezpieczeń online	factor
11	OnlineBackup	Czy klient ma usługę backupu online	factor
12	DeviceProtection	Czy klient ma usługę ochrony urządzeń	factor
13	TechSupport	Czy klient ma wsparcie techniczne	factor
14	StreamingTV	Czy klient ma usługę TV streamingowego	factor
15	StreamingMovies	Czy klient ma usługę filmów streamingowych	factor
16	Contract	Typ umowy (Month-to-month, One year, Two year)	factor
17	PaperlessBilling	Czy klient korzysta z e-faktury (Yes, No)	factor
18	PaymentMethod	Metoda płatności	factor
19	MonthlyCharges	Miesięczna opłata (w dolarach)	numeric
20	TotalCharges	Łączne opłaty (w dolarach)	numeric
21	Churn	Czy klient odszedł (Yes, No)	factor

```
## [1] 7043   21
```

W zestawie danych mamy 7043 obserwacji i 21 zmiennych.

```
# Usuwamy klucz główny, bo nie przyda się w analizie danych
data$customerID <- NULL
```

Sprawdzamy, ile wartości brakuje w każdej kolumnie zbioru danych:

```
colSums(is.na(data))
```

```
##           gender    SeniorCitizen          Partner       Dependents
##                0                0                0                0
##           tenure     PhoneService    MultipleLines  InternetService
##                0                0                0                0
##   OnlineSecurity     OnlineBackup DeviceProtection      TechSupport
##                0                0                0                0
##      StreamingTV  StreamingMovies         Contract PaperlessBilling
##                0                0                0                0
##    PaymentMethod   MonthlyCharges     TotalCharges            Churn
##                0                0               11                0
```

Widzimy, że braki występują głównie w zmiennej *TotalCharges*. Po sprawdzeniu:

```
data[is.na(data$TotalCharges), "tenure"]
```

```
##  [1] 0 0 0 0 0 0 0 0 0 0 0
```

możemy stwierdzić, że brak wartości w *TotalCharges* dotyczy klientów, którzy dopiero rozpoczęli subskrypcję (mają `tenure` równy 0).

Dla zmiennych takich jak *tenure*, *MonthlyCharges* oraz *TotalCharges* wyznaczymy:

- Liczebność obserwacji (n)
- Średnią (mean)
- Medianę
- Odchylenie standardowe (std)
- Wartości minimalne i maksymalne
- Kwartyle (Q1, Q3)
- Odchylenie standardowe

```
summary(data$tenure)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.00    9.00   29.00   32.37   55.00   72.00
```

```
summary(data$MonthlyCharges)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   18.25   35.50   70.35   64.76   89.85  118.75
```

```
summary(data$TotalCharges)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
##    18.8   401.4  1397.5  2283.3  3794.7  8684.8      11
```

```
## Odchylenie standardowe dla tenure: 24.55948
```

```
## Odchylenie standardowe dla MonthlyCharges: 30.09005
```

```
## Odchylenie standardowe dla TotalCharges: 2266.771
```

Dla zmiennych takich jak *gender*, *SeniorCitizen*, *Partner*, *Dependents*, *PhoneService*, *InternetService*, *Contract*, *PaymentMethod* czy *Churn* warto przedstawić ich rozkład.

```r
table(data$gender)
```

```
##
## Female   Male
##   3488   3555
```

```r
table(data$SeniorCitizen)
```

```
##
##    0    1
## 5901 1142
```

```r
table(data$Partner)
```

```
##
##   No  Yes
## 3641 3402
```

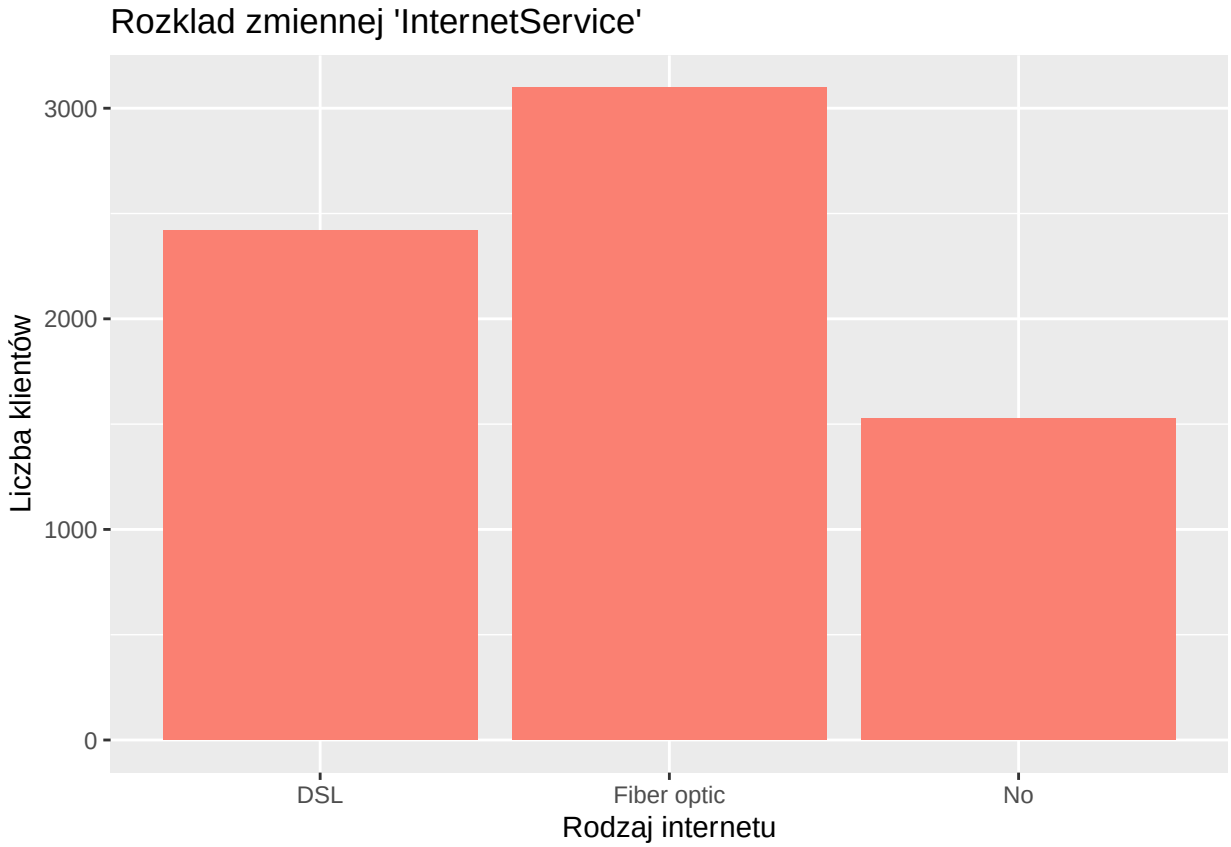
```r
table(data$Churn)
```

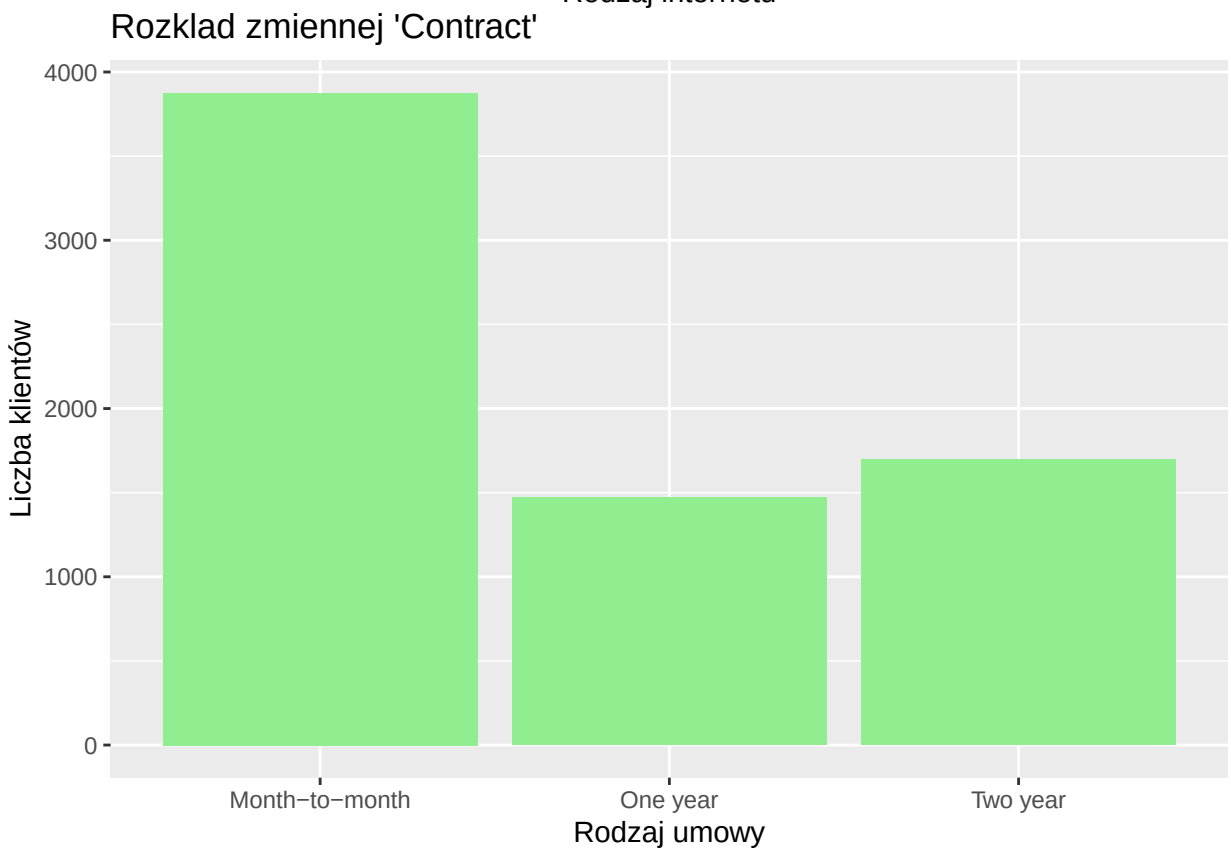
```
##
##   No  Yes
## 5174 1869
```

```r
# Procentowy udział
prop.table(table(data$Churn)) * 100
```

```
##
##       No      Yes
## 73.46301 26.53699
```

Dla przykładu wykreślimy wykresy słupkowe dla zmiennych *InternetService* oraz *Contract*.





Przedstawimy histogramy i wykresy pudełkowe dla zmiennych **tenure**, **MonthlyCharges** i **TotalCharges**.

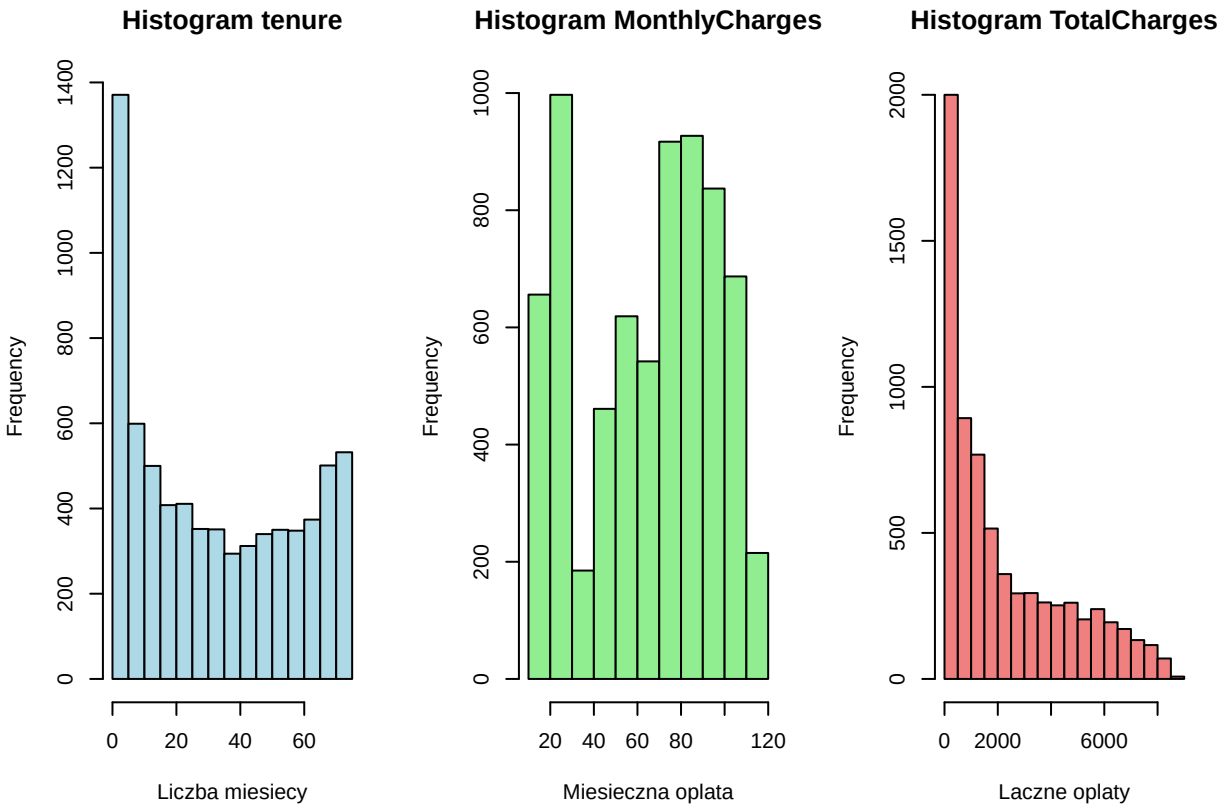


Figure 1: Histogramy zmiennych numerycznych

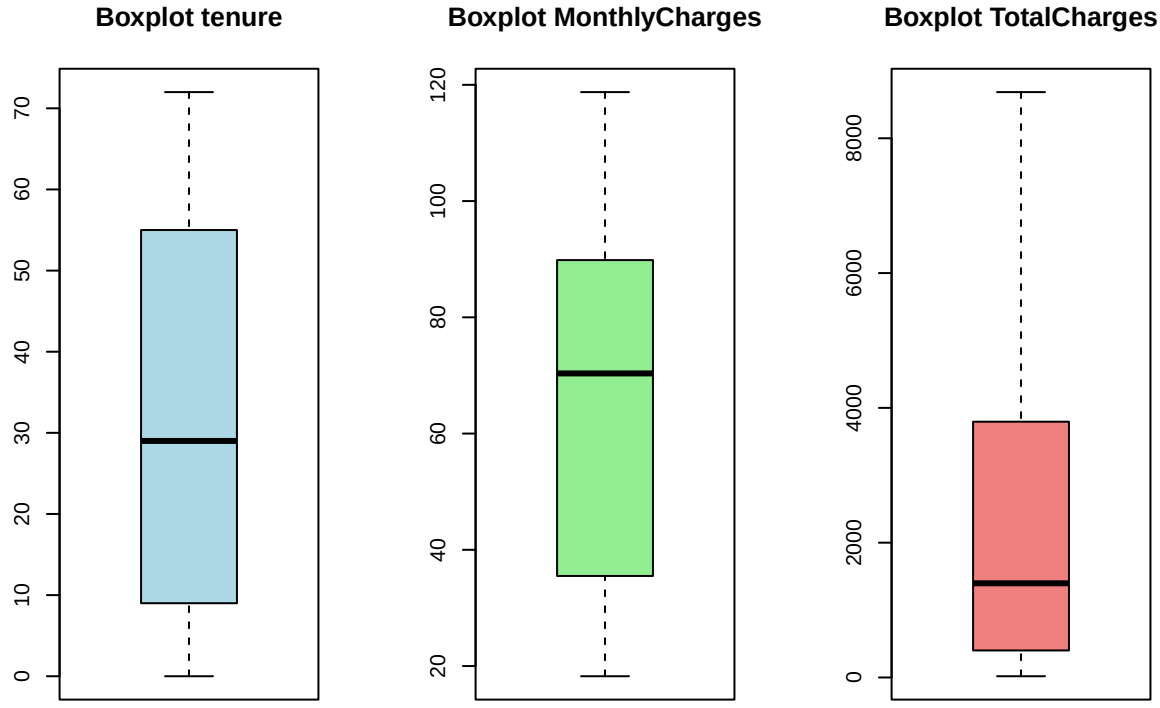


Figure 2: Boxploty zmiennych numerycznych

Przeanalizujemy zależności między wybranymi !!

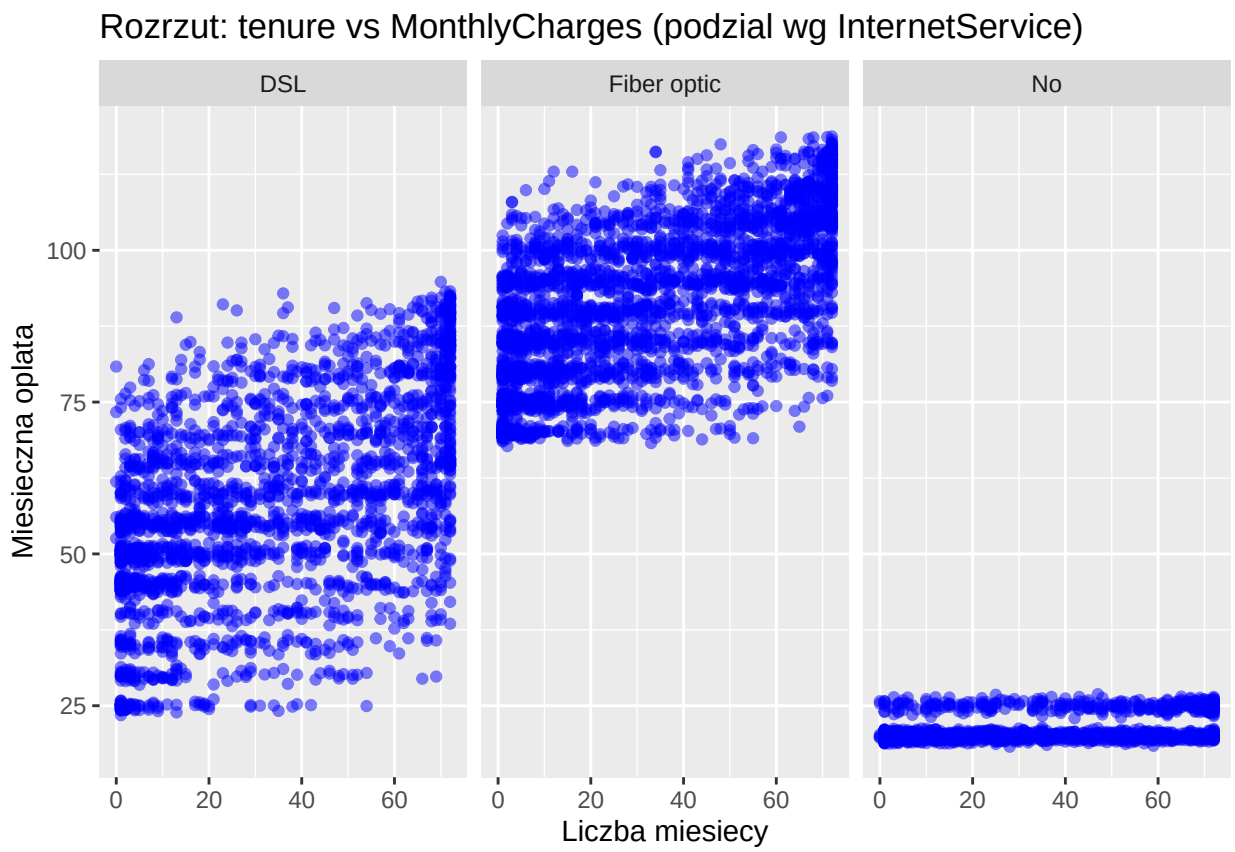


Figure 3: Wykres rozrzutu: tenure vs MonthlyCharges podzielony według InternetService

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 11 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 11 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 11 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 11 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

Dodatkowo, wyznaczymy współczynniki korelacji między tymi zmiennymi:

```
## Korelacja między tenure a MonthlyCharges: 0.2478999
```

```
## Korelacja między tenure a TotalCharges: 0.8258805
```

```
## Korelacja między MonthlyCharges a TotalCharges: 0.6510648
```

Warto jednak zaznaczyć, że gdy podzielimy dane *MonthlyCharges* ze względu na *InternetService* współczynniki korelacji się zmienia

```
##         DSL Fiber optic          No
```

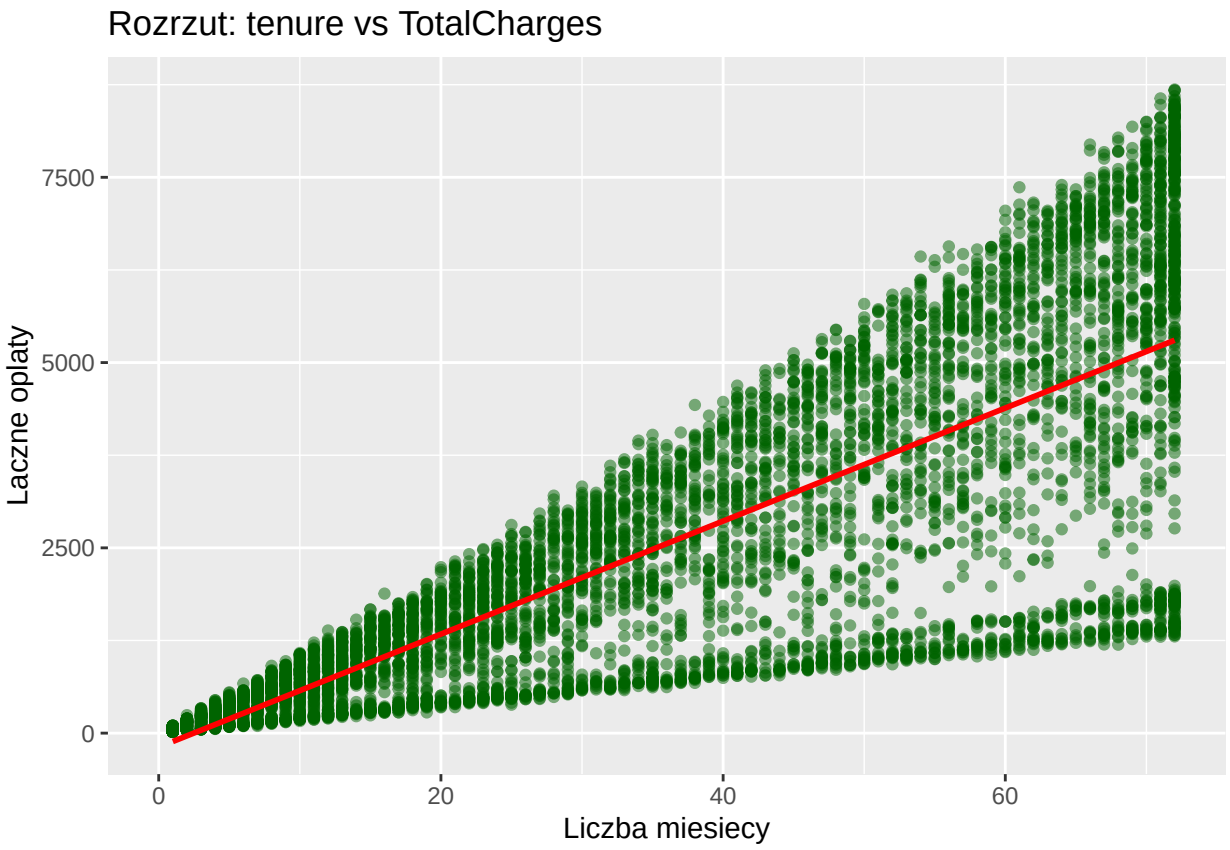


Figure 4: Wykres rozrzutu: tenure vs TotalCharges

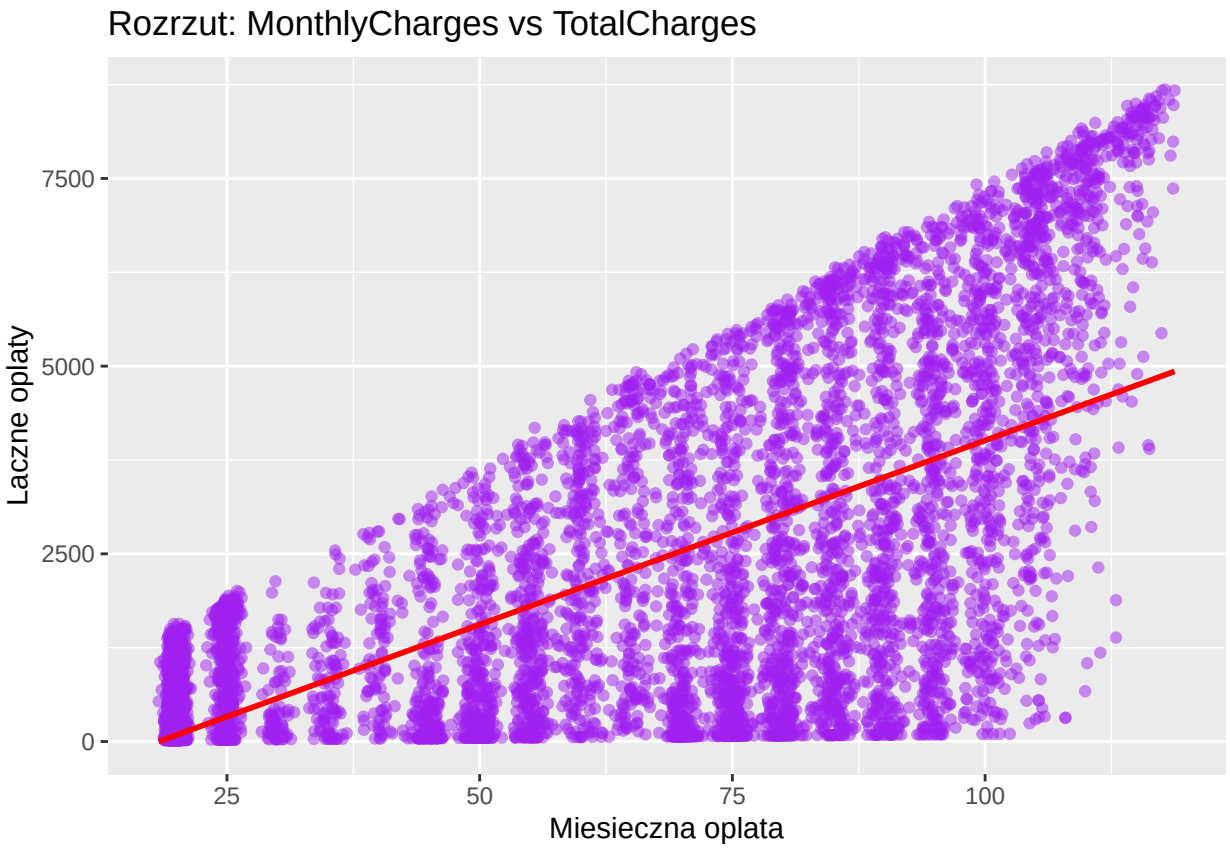
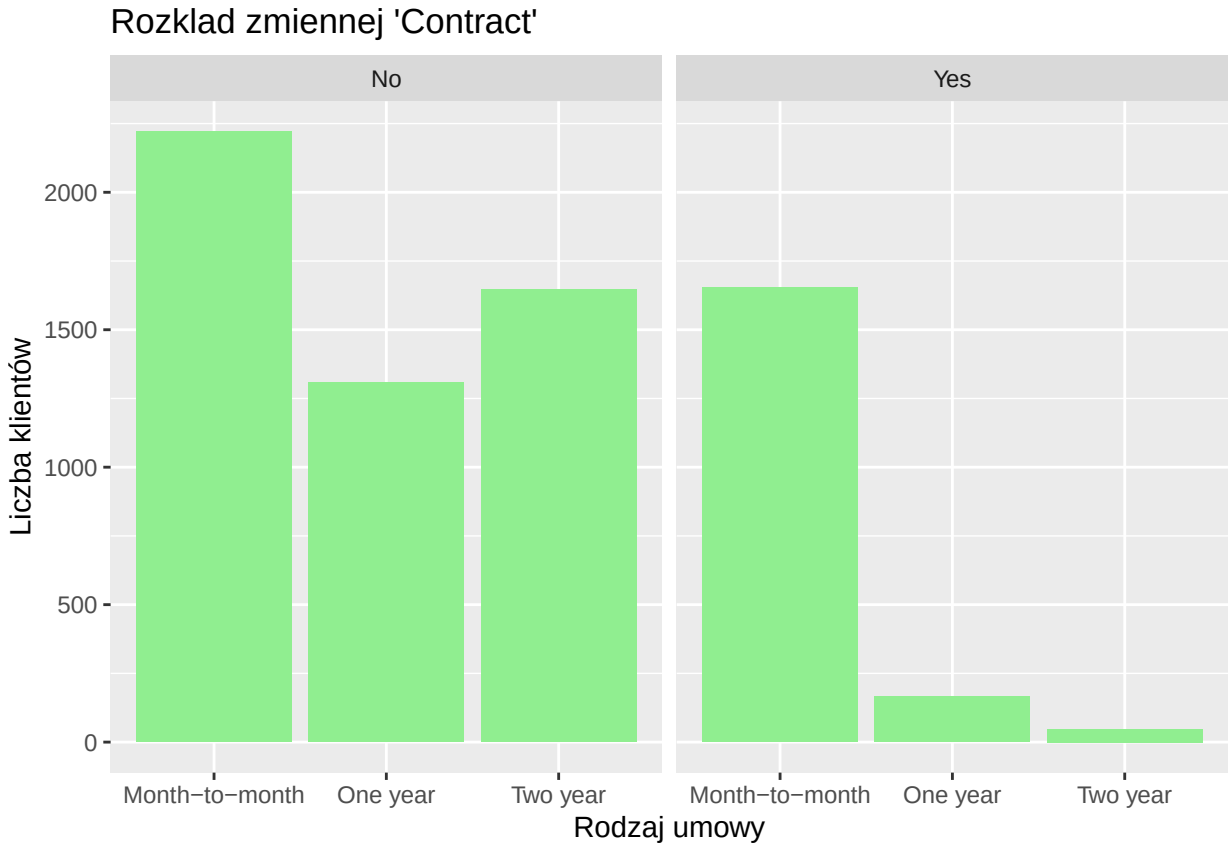


Figure 5: Wykres rozrzutu: MonthlyCharges vs TotalCharges

```
##    0.7178911    0.7135249    0.4844854
```

Postarajmy sie teraz odpowiedziec Chrun = Yes / No!!!




```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 11 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 11 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 11 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 11 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!Reszta dla cb :) W jezeli cos stwierdzamy w komentarzu zawsze ma byc odwołanie do chunka Rysunek **??** pokazuje że jest zależność

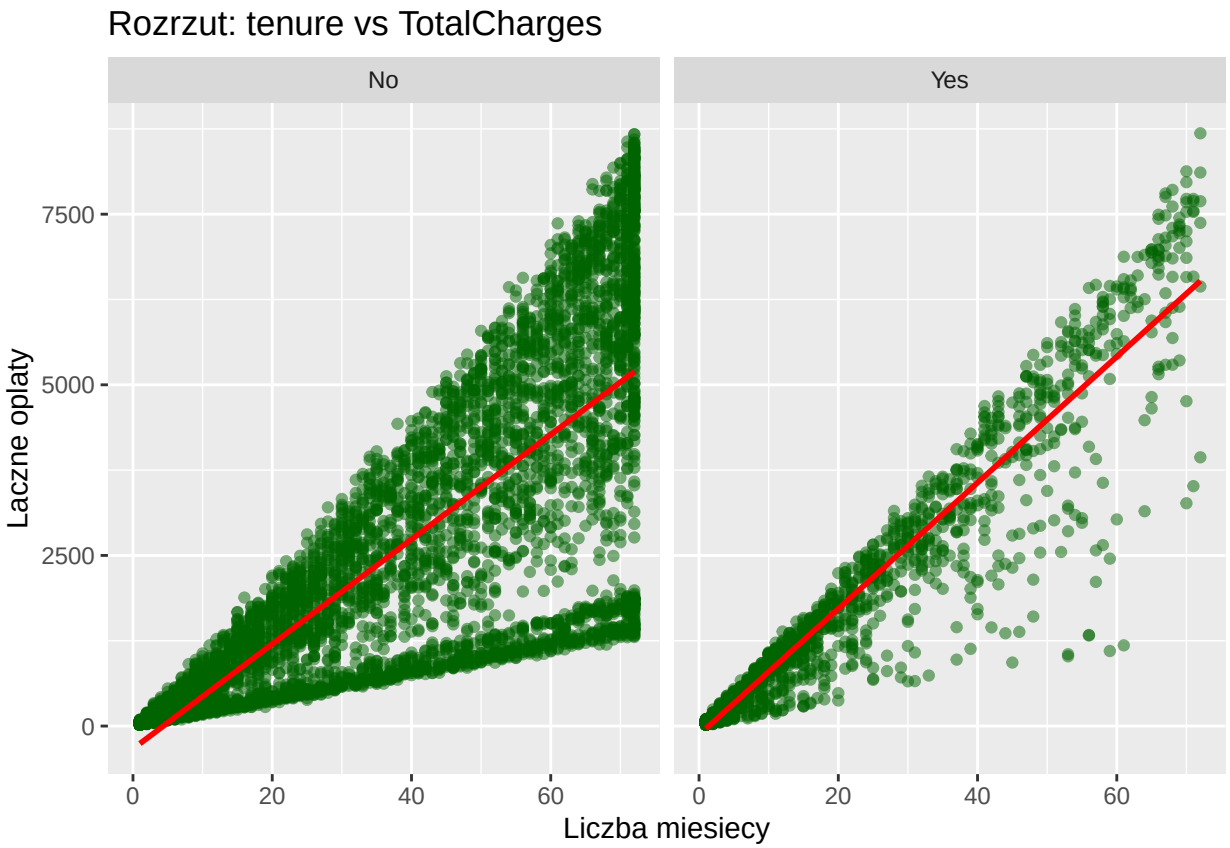


Figure 6: Wykres rozrzutu: tenure vs TotalCharges vs Churn

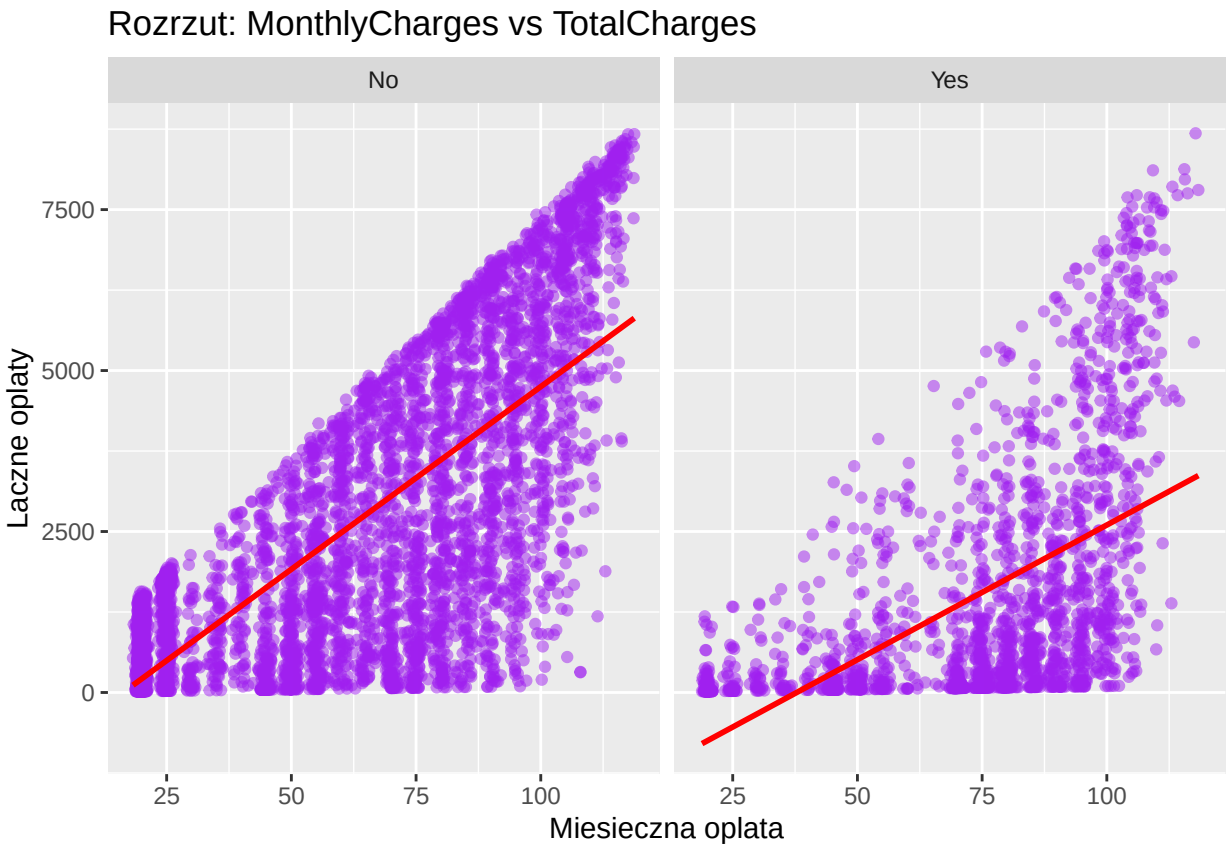


Figure 7: Wykres rozrzutu: MonthlyCharges vs TotalCharges vs Churn