Raport 3

Eksploracja danych

Michał Frąckowiak 275951 Matusz Goszczyński 275959

2025-06-03

Spis treści

1 Krótki opis zagadnienia **1**

2 Wyniki **2**

3 Podsumowanie **11**

1 Krótki opis zagadnienia

Celem niniejszej analizy jest zbadanie możliwości zastosowania regresji liniowej jako metody klasyfikacji danych. W tym celu wykorzystano klasyczny zbiór danych iris zawierający pomiary czterech cech botanicznych trzech gatunków irysów. Problem klasyfikacji polega na przypisaniu nowej obserwacji do jednej z trzech klas na podstawie dostępnych cech ilościowych.

Analiza ma na celu odpowiedzieć na następujące pytania:

- Czy regresja liniowa może skutecznie rozdzielać klasy w zadaniu klasyfikacyjnym?
- Jakie są ograniczenia klasyfikatora liniowego w kontekście nakładających się klas?
- Czy rozszerzenie przestrzeni cech o składniki wielomianowe poprawia jakość klasyfikacji?

Tabela 1: Opis zmiennych w zbiorze danych iris

Nazwa.zmiennej	Typ.zmiennej	Opis	Rola
Sepal.Length	numeryczna (ciągła)	Długość działki kielicha w centymetrach	zmienna objaśniając
Sepal.Width	numeryczna (ciągła)	Szerokość działki kielicha w centymetrach	zmienna objaśniając
Petal.Length	numeryczna (ciągła)	Długość płatka w centymetrach	zmienna objaśniając
Petal.Width	numeryczna (ciągła)	Szerokość płatka w centymetrach	zmienna objaśniając
Species	kategoryczna (factor)	Gatunek irysa, jeden z trzech: setosa, versicolor, virginica	zmienna celu

2 Wyniki

```r
# Podział na dane testowe i uczące
n <- nrow(iris)
train_indices <- sample(1:n, size = round(2/3 * n))
iris_train <- iris[train_indices, ]
iris_test <- iris[-train_indices, ]
```

```r
# Tworzenie klas
iris_train$Y_setosa <- as.numeric(iris_train$Species == "setosa")
iris_train$Y_versicolor <- as.numeric(iris_train$Species == "versicolor")
iris_train$Y_virginica <- as.numeric(iris_train$Species == "virginica")

# Regresja liniowa
model_setosa <- lm(Y_setosa ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.Width, d
model_versicolor <- lm(Y_versicolor ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.
model_virginica <- lm(Y_virginica ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.Wi

# Prognozy
predict_class <- function(data) {
  p1 <- predict(model_setosa, newdata = data)
  p2 <- predict(model_versicolor, newdata = data)
  p3 <- predict(model_virginica, newdata = data)

  pred <- apply(cbind(p1, p2, p3), 1, function(x) c("setosa", "versicolor", "virginica"
  return(factor(pred, levels = levels(iris$Species)))
}

pred_train <- predict_class(iris_train)
pred_test <- predict_class(iris_test)
```

```
## prognozowane etykiety klas na zbiorze uczącym
```

```
##         69        146        149        118         72
## versicolor  virginica  virginica  virginica versicolor
## Levels: setosa versicolor virginica
```

```
## prognozowane etykiety klas na zbbiorze testowym
```

```
##      1      6      8     11     13
## setosa setosa setosa setosa setosa
## Levels: setosa versicolor virginica
```

Zastosowano *regresję liniową osobno dla każdej klasy*(2), a następnie przypisano obserwacji klasę z największą wartością prognozowanej zmiennej.

```
# Zbiór uczący
cm_train <- table(Prawdziwe = iris_train$Species, Przewidziane = pred_train)
error_train <- mean(pred_train != iris_train$Species)

# Zbiór testowy
cm_test <- table(Prawdziwe = iris_test$Species, Przewidziane = pred_test)
error_test <- mean(pred_test != iris_test$Species)

print(cm_train)
```

```
##             Przewidziane
## Prawdziwe    setosa versicolor virginica
##   setosa         35          0         0
##   versicolor      0         20         9
##   virginica       0          3        33
```

```
print(paste("Blad klasyfikacji (train):", round(error_train, 3)))
```

```
## [1] "Blad klasyfikacji (train): 0.12"
```

```
print(cm_test)
```

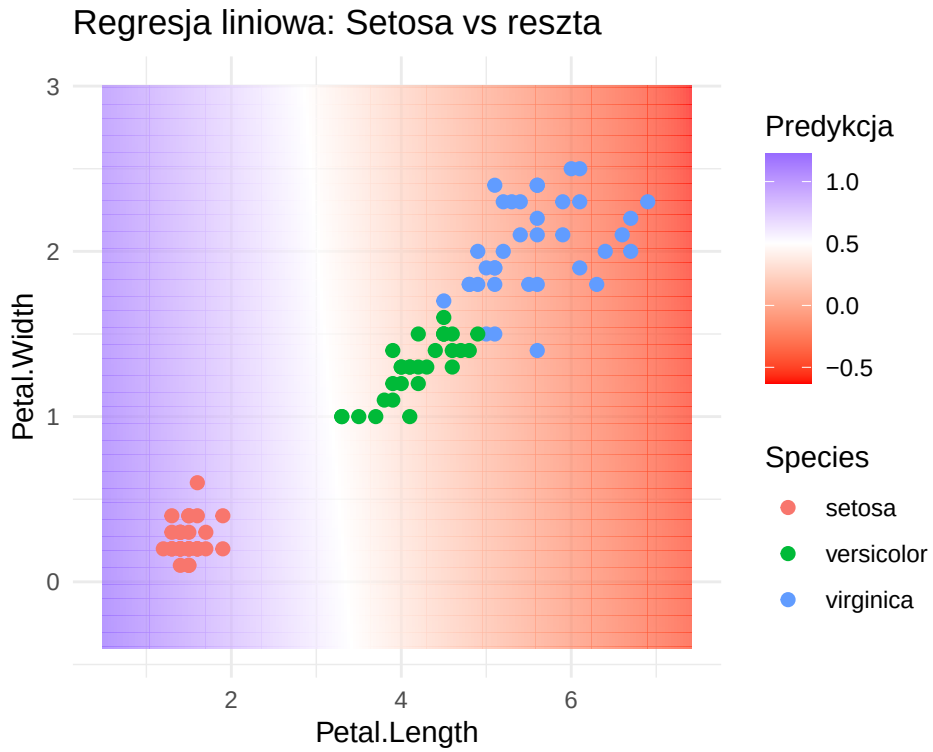
```
##             Przewidziane
## Prawdziwe    setosa versicolor virginica
##   setosa         15          0         0
##   versicolor      0         11        10
##   virginica       0          1        13
```

```
print(paste("Blad klasyfikacji (test):", round(error_test, 3)))
```

```
## [1] "Blad klasyfikacji (test): 0.22"
```

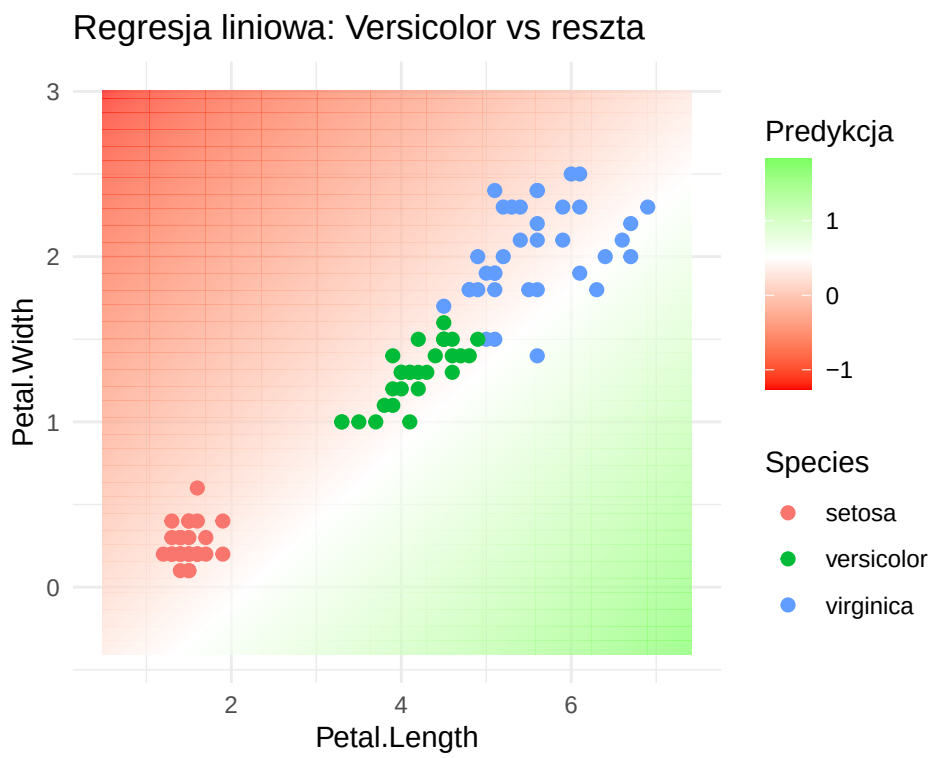
Na podstawie zbioru uczącego wyznaczono estymatory, a następnie przeprowadzono klasyfikację zarówno na zbiorze uczącym, jak i testowym.(2)

```
## [1] "Calkowita liczba obserwacji: 100"
## [1] "Poprawnie zaklasyfikowane: 88"
## [1] "Bledy: 12"
## [1] "Dokladnosc: 0.88"
## [1] "setosa: 35/35 (100%)"
## [1] "versicolor: 20/29 (69%)"
## [1] "  - mylone z setosa: 0"
## [1] "  - mylone z virginica: 9"
## [1] "virginica: 33/36 (91.7%)"
## [1] "  - mylone z setosa: 0"
## [1] "  - mylone z versicolor: 3"
```



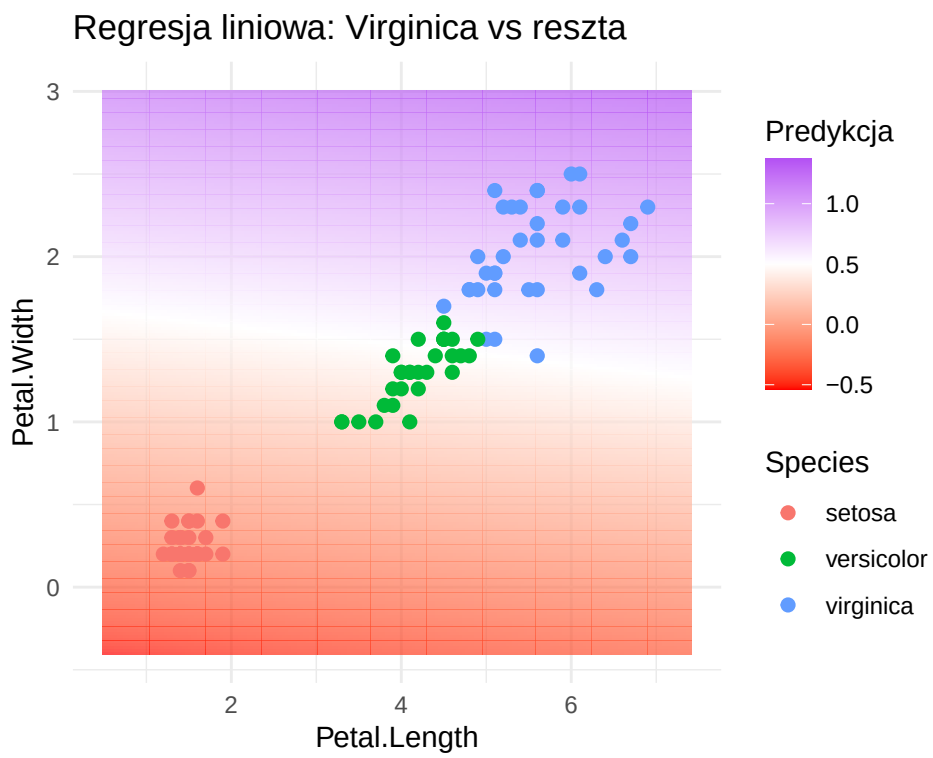
Rysunek 1: Wizualizacja 1

Model nie ma problemów z rozróżnieniem Setosa od pozostałych gatunków. Maskowanie klas nie występuje.1



Rysunek 2: Wizualizacja 2

Model ma największe problemy z rozróżnieniem Virginica od pozostałych gatunków. Najszerszy pas niepewności i najwięcej błędnie sklasyfikowanych punktów. Znaczące nakładanie się z Versicolor, nieregularna granica decyzyjna. Występuje częściowe maskowanie klas.2



Rysunek 3: Wizualizacja 3

Model ma umiarkowane problemy z rozróżnieniem, szczególnie między Versicolor a Virginica. Szerszy biały pas niepewności wskazuje na większe trudności modelu. Występuje całkowite maskowanie klas.3

```
# Funkcja do rozszerzania danych o cechy wielomianowe drugiego stopnia
add_poly_features <- function(data) {
  data$PL2 <- data$Petal.Length^2
  data$PW2 <- data$Petal.Width^2
  data$SL2 <- data$Sepal.Length^2
  data$SW2 <- data$Sepal.Width^2

  data$PL_PW <- data$Petal.Length * data$Petal.Width
  data$PL_SW <- data$Petal.Length * data$Sepal.Width
  data$PL_SL <- data$Petal.Length * data$Sepal.Length
  data$PW_SL <- data$Petal.Width * data$Sepal.Length
  data$PW_SW <- data$Petal.Width * data$Sepal.Width
  data$SL_SW <- data$Sepal.Length * data$Sepal.Width

  return(data)
}
```

```r
iris_train <- add_poly_features(iris_train)
iris_test <- add_poly_features(iris_test)
```

```r
# Tworzenie klas
iris_train$Y_setosa <- as.numeric(iris_train$Species == "setosa")
iris_train$Y_versicolor <- as.numeric(iris_train$Species == "versicolor")
iris_train$Y_virginica <- as.numeric(iris_train$Species == "virginica")

# Regresja liniowa

model_setosa <- lm(Y_setosa ~ Sepal.Length + Sepal.Width +
                     Petal.Length + Petal.Width +
                     PL2 + PW2 + SL2 + SW2 + PL_PW + PL_SW + PL_SL +
                     PW_SL + PW_SW + SL_SW, data = iris_train)

model_versicolor <- lm(Y_versicolor ~ Sepal.Length + Sepal.Width +
                         Petal.Length + Petal.Width +
                         PL2 + PW2 + SL2 + SW2 + PL_PW + PL_SW + PL_SL +
                         PW_SL + PW_SW + SL_SW, data = iris_train)

model_virginica <- lm(Y_virginica ~ Sepal.Length + Sepal.Width +
                        Petal.Length + Petal.Width +
                        PL2 + PW2 + SL2 + SW2 + PL_PW + PL_SW + PL_SL +
                        PW_SL + PW_SW + SL_SW, data = iris_train)

# Prognozy
predict_class <- function(data) {
  p1 <- predict(model_setosa, newdata = data)
  p2 <- predict(model_versicolor, newdata = data)
  p3 <- predict(model_virginica, newdata = data)

  pred <- apply(cbind(p1, p2, p3), 1, function(x) c("setosa", "versicolor", "virginica"
  return(factor(pred, levels = levels(iris$Species)))
}

pred_train <- predict_class(iris_train)
pred_test <- predict_class(iris_test)
```

```
##             Przewidziane
## Prawdziwe    setosa versicolor virginica
##   setosa         35          0         0
##   versicolor      0         29         0
##   virginica       0          2        34
```

```
## [1] "Blad klasyfikacji (train): 0.02"
```

```
##             Przewidziane
## Prawdziwe    setosa versicolor virginica
##   setosa         15          0         0
##   versicolor      0         20         1
##   virginica       0          1        13
```

```
## [1] "Blad klasyfikacji (test): 0.04"
```

Widać znaczącą poprawe względem pierwotnych danych(2)

```
## [1] "Calkowita liczba obserwacji: 100"
```

```
## [1] "Poprawnie zaklasyfikowane: 98"
```

```
## [1] "Bledy: 2"
```

```
## [1] "Dokladnosc: 0.98"
```

```
## [1] "setosa: 35/35 (100%)"
```

```
## [1] "versicolor: 29/29 (100%)"
```

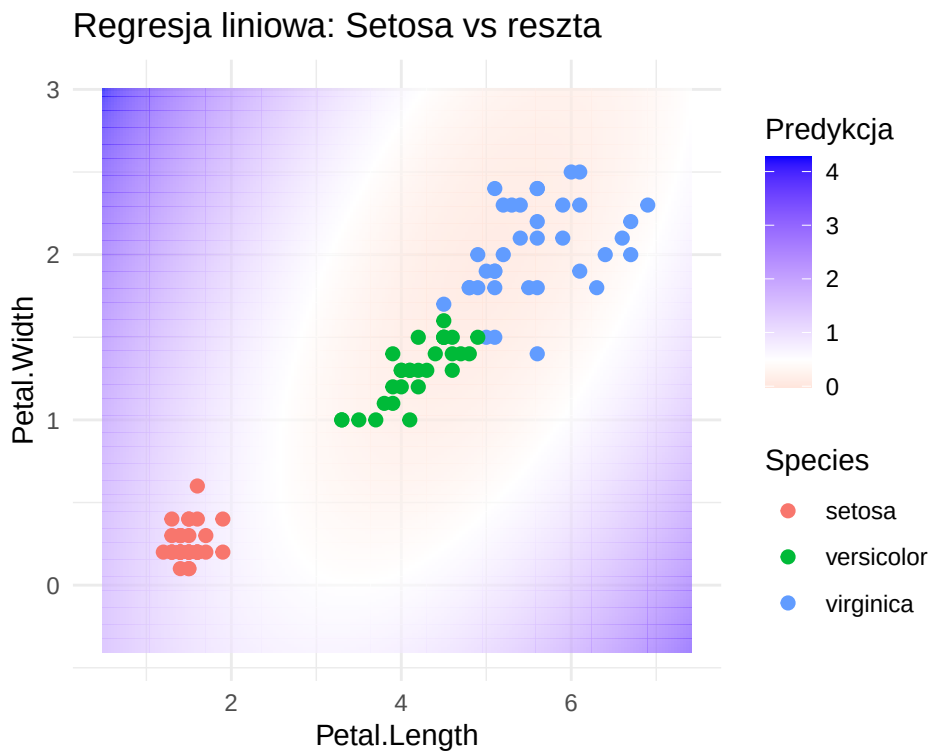
```
## [1] "  - mylone z setosa: 0"
```

```
## [1] "  - mylone z virginica: 0"
```

```
## [1] "virginica: 34/36 (94.4%)"
```

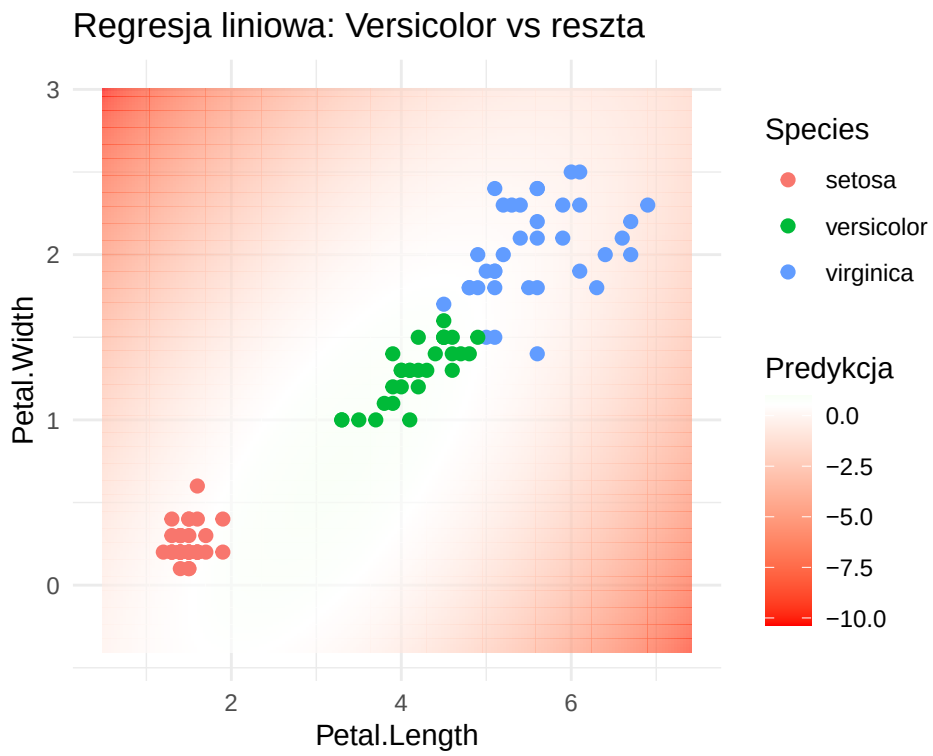
```
## [1] "  - mylone z setosa: 0"
```

```
## [1] "  - mylone z versicolor: 2"
```



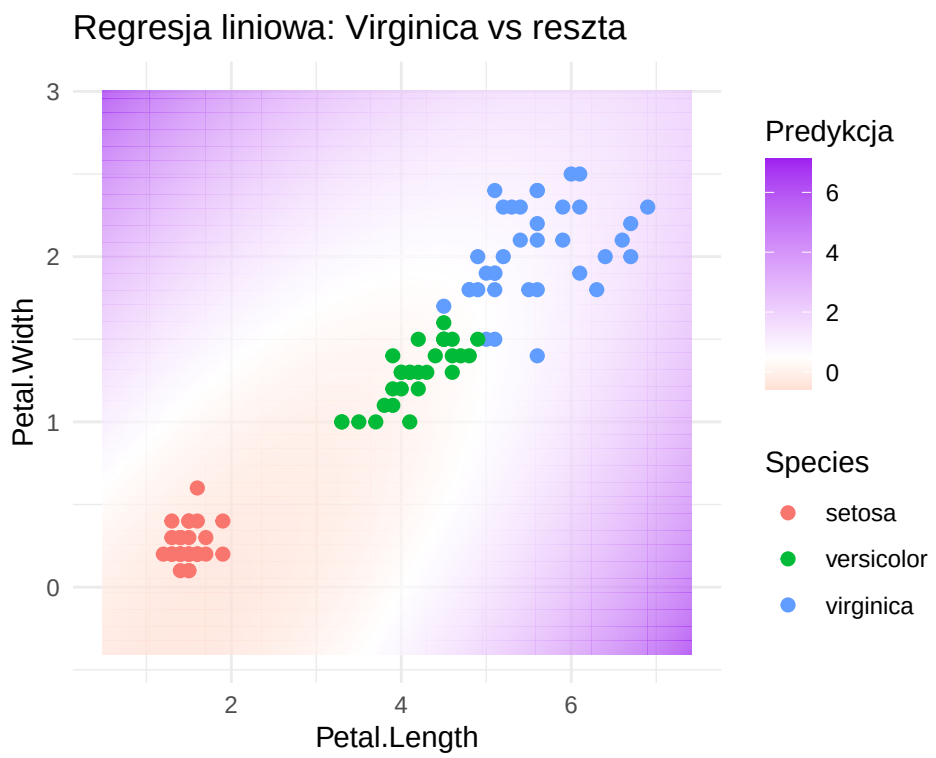
Rysunek 4: Wizualizacja 4

Model nie ma problemów z rozróżnieniem Setosa od pozostałych gatunków. Maskowanie klas nie występuje.4



Rysunek 5: Wizualizacja 5

Model ma większe problemy z rozróżnieniem Virginica od pozostałych gatunków. Najszerszy pas niepewności. Znaczące nakładanie się z Versicolor, nieregularna granica decyzyjn jednak jest zdecydowana porawa względem danych pierwotnych. Występuje częściowe maskowanie klas.**??**



Rysunek 6: Wizualizacja 6

Model ma umiarkowane problemy z rozróżnieniem, szczególnie między Versicolor a Virginica, jednak jest znaczna poprawa w porównaniu z danymi pierwotnymi. Maskowanie klas nie występuje.6

3 Podsumowanie

1. *Model regresji liniowej* zastosowany jako klasyfikator wieloklasowy okazał się częściowo skuteczny. Klasa setosa została rozpoznana z bardzo dużą dokładnością, co sugeruje jej dobrą separowalność w przestrzeni cech.1
2. Dla klas versicolor oraz virginica zauważono częściowe *nakładanie się granic decyzyjnych*, co prowadziło do błędów klasyfikacji. Potwierdza to występowanie zjawiska *maskowania klas*, o którym była mowa na wykładzie.2.3
3. Wprowadzenie *rozszerzonej przestrzeni cech* poprzez składniki wielomianowe drugiego stopnia przyczyniło się do poprawy jakości klasyfikacji, szczególnie dla klas trudniejszych do rozróżnienia. Obserwuje się zmniejszenie błędów klasyfikacji oraz lepsze dopasowanie modelu.4.5.6