Krótki opis zagadnienia

Naszym celem jest eksploracja danych dotyczących klientów firmy telekomunikacyjnej oraz analiza czynników wpływających na ich rezygnację z usług. W szczególności:

- Jakie cechy klientów wpływają na decyzję o rezygnacji?
- Jakie są główne różnice między klientami, którzy pozostają, a tymi, którzy odchodzą?
- Czy można przewidzieć odejście klienta na podstawie dostępnych danych?

Opis eksperymentów/analiz

- **Dane**: Zbiór *WA_Fn-UseC_-Telco-Customer-Churn.csv* (źródło: Kaggle).
- **Eksperymenty**:
  - Wczytanie i wstępna eksploracja danych.
  - Analiza opisowa zmiennych.
  - Podział klientów na grupy (Churn = "Yes" vs Churn = "No").
  - Wizualizacja rozkładu cech i zależności między zmiennymi.
- **Narzędzia**:
  - Wykresy (histogramy, pudełkowe, słupkowe, rozrzutu).
  - Wskaźniki statystyczne (średnia, mediana, odchylenie standardowe).

!! !!!!!!!!!!!!!!!!!!!!!!!!!!!!!!! !!!!!!!!!!!!! !!!!!!!!!!!!!!!!

Table 1: Tabela: Opis zmiennych w zbiorze Telco Customer Churn

Lp	Nazwa_zmiennej	Opis_zmiennej	Typ
1	customerID	Unikalny identyfikator klienta	character
2	gender	Płeć klienta (Male, Female)	factor
3	SeniorCitizen	Czy klient jest seniorem (0 = Nie, 1 = Tak)	numeric
4	Partner	Czy klient ma partnera (Yes, No)	factor
5	Dependents	Czy klient ma osoby na utrzymaniu (Yes, No)	factor
6	tenure	Liczba miesięcy bycia klientem	numeric
7	PhoneService	Czy klient ma usługę telefoniczną (Yes, No)	factor
8	MultipleLines	Czy klient ma wiele linii telefonicznych	factor
9	InternetService	Rodzaj internetu (DSL, Fiber optic, No)	factor
10	OnlineSecurity	Czy klient ma usługę zabezpieczeń online	factor
11	OnlineBackup	Czy klient ma usługę backupu online	factor
12	DeviceProtection	Czy klient ma usługę ochrony urządzeń	factor
13	TechSupport	Czy klient ma wsparcie techniczne	factor
14	StreamingTV	Czy klient ma usługę TV streamingowego	factor
15	StreamingMovies	Czy klient ma usługę filmów streamingowych	factor
16	Contract	Typ umowy (Month-to-month, One year, Two year)	factor
17	PaperlessBilling	Czy klient korzysta z e-faktury (Yes, No)	factor
18	PaymentMethod	Metoda płatności	factor
19	MonthlyCharges	Miesięczna opłata (w dolarach)	numeric
20	TotalCharges	Łączne opłaty (w dolarach)	numeric
21	Churn	Czy klient odszedł (Yes, No)	factor

```
## [1] 7043   21
```

W zestawie danych mamy 7043 cechy oraz 21 przypadków.

```r
# usuwamy klucz główny bo nie przyda nam sie w analizie danych
data$customerID <- NULL
```

Sprawdzamy, ile wartości brakuje w każdej kolumnie zbioru danych.

```
colSums(is.na(data))
```

```
##           gender    SeniorCitizen          Partner       Dependents
##                0                0                0                0
##           tenure     PhoneService    MultipleLines  InternetService
##                0                0                0                0
##   OnlineSecurity     OnlineBackup DeviceProtection      TechSupport
##                0                0                0                0
##      StreamingTV  StreamingMovies         Contract PaperlessBilling
##                0                0                0                0
##    PaymentMethod   MonthlyCharges     TotalCharges            Churn
##                0                0               11                0
```

Należy zweryfikować, w których przypadkach występują brakujące dane.

```
data[is.na(data$TotalCharges), "tenure"]
```

```
##  [1] 0 0 0 0 0 0 0 0 0 0 0
```

Brak wartości w “TotalCharges” oznacza, że klient dopiero rozpoczął subskrypcję. Klienci ci mają “tenure” równy 0, co oznacza, że nie byli jeszcze rozliczani.

Sprawdzmy czy występują wartości nietypowe

```
# Unikalne wartości
# sapply(data, unique)
```

W zbiorze danych nie występują wartości nietypowe.

```
par(mfrow = c(1,3))

hist(data$MonthlyCharges, main="Miesięczne opłaty", ylab="srednie wydatki", xlab="Ile osob")
hist(data$TotalCharges, main="Łączne wydatki", ylab="Łączne wydatki", xlab = "Ile osob")

hist(as.numeric(data$SeniorCitizen), main = "Emeryci", ylab="ile osob", breaks = 2, xlab = "młodzi/star
```

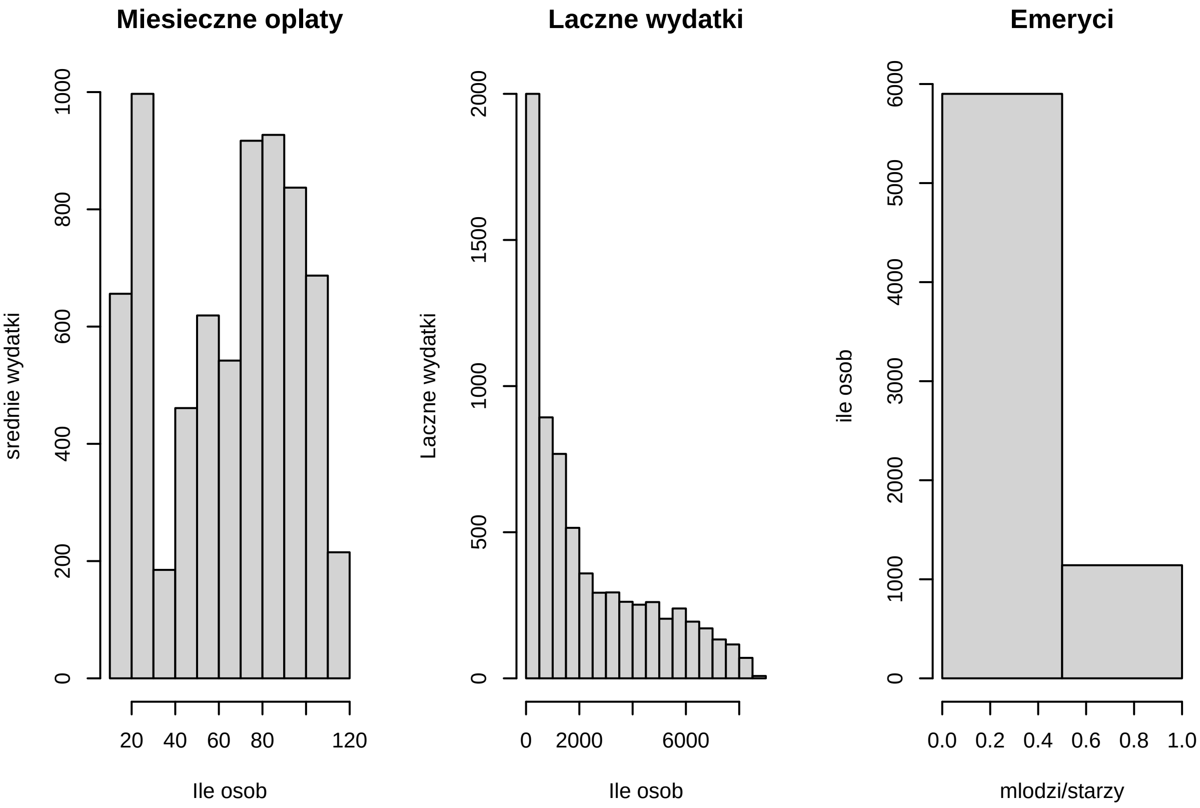

Figure 1: Rozkladyzmiennych