Raport 1

Eksploracja danych

Michał Frąckowiak 275951 Matusz Goszczyński 275959

2025-04-02

Spis treści

1 Krótki opis zagadnienia **2**

2 Opis eksperymentów/analiz **2**

3 Opis zmiennych **3**

4 Wyniki **5**

5 Podsumowanie **15**

1 Krótki opis zagadnienia

Naszym celem jest eksploracja danych dotyczących klientów firmy telekomunikacyjnej oraz analiza czynników wpływających na ich rezygnację z usług. W szczególności:

- Jakie cechy klientów wpływają na decyzję o rezygnacji?
- Jakie są główne różnice między klientami, którzy pozostają, a tymi, którzy odchodzą?
- Czy można przewidzieć odejście klienta na podstawie dostępnych danych?

2 Opis eksperymentów/analiz

- *Dane*: Zbiór *WA_Fn-UseC_-Telco-Customer-Churn.csv* (źródło: Kaggle).
- *Eksperymenty*:
  - Wczytanie i wstępna eksploracja danych.
  - Analiza opisowa zmiennych.
  - Podział klientów na grupy (Churn = "Yes" vs Churn = "No").
  - Wizualizacja rozkładu cech i zależności między zmiennymi.
- *Narzędzia*:
  - Wykresy (histogramy, pudełkowe, słupkowe, wykresy rozrzutu).
  - Wskaźniki statystyczne (średnia, mediana, odchylenie standardowe).

3 Opis zmiennych

```
data <- read.csv("WA_Fn-UseC_-Telco-Customer-Churn.csv",
                 sep = ",", header = TRUE, stringsAsFactors = TRUE)
```

	Lp	Nazwa_zmiennej	Opis_zmiennej	Typ
1	1	customerID	Unikalny identyfikator klienta	character
2	2	gender	Płeć klienta (Male, Female)	factor
3	3	SeniorCitizen	Czy klient jest seniorem (0 = Nie, 1 = Tak)	numeric
4	4	Partner	Czy klient ma partnera (Yes, No)	factor
5	5	Dependents	Czy klient ma osoby na utrzymaniu (Yes, No)	factor
6	6	tenure	Liczba miesięcy bycia klientem	numeric
7	7	PhoneService	Czy klient ma usługę telefoniczną (Yes, No)	factor
8	8	MultipleLines	Czy klient ma wiele linii telefonicznych	factor
9	9	InternetService	Rodzaj internetu (DSL, Fiber optic, No)	factor
10	10	OnlineSecurity	Czy klient ma usługę zabezpieczeń online	factor
11	11	OnlineBackup	Czy klient ma usługę backupu online	factor
12	12	DeviceProtection	Czy klient ma usługę ochrony urządzeń	factor
13	13	TechSupport	Czy klient ma wsparcie techniczne	factor
14	14	StreamingTV	Czy klient ma usługę TV streamingowego	factor
15	15	StreamingMovies	Czy klient ma usługę filmów streamingowych	factor
16	16	Contract	Typ umowy (Month-to-month, One year, Two year)	factor
17	17	PaperlessBilling	Czy klient korzysta z e-faktury (Yes, No)	factor
18	18	PaymentMethod	Metoda płatności	factor
19	19	MonthlyCharges	Miesięczna opłata (w dolarach)	numeric
20	20	TotalCharges	Łączne opłaty (w dolarach)	numeric
21	21	Churn	Czy klient odszedł (Yes, No)	factor

Tabela 1: Opis zmiennych w zbiorze Telco Customer Churn

Jak widać w Tabeli(1), zbiór zawiera różne typy zmiennych opisujących zachowania klientów. Nasz próbka zawiera

```
cat(dim(data)[1]," obserwacji i ", dim(data)[2]," zmiennych.")
```

```
## 7043  obserwacji i  21  zmiennych.
```

Usuwamy klucz główny, bo nie przyda się w analizie danych

```
data$customerID <- NULL
```

Sprawdzamy, ile wartości brakuje w każdej kolumnie zbioru danych:

```
colSums(is.na(data))
```

```
##           gender    SeniorCitizen          Partner       Dependents
##                0                0                0                0
##           tenure     PhoneService    MultipleLines  InternetService
##                0                0                0                0
##   OnlineSecurity     OnlineBackup DeviceProtection      TechSupport
##                0                0                0                0
##      StreamingTV  StreamingMovies         Contract PaperlessBilling
##                0                0                0                0
##    PaymentMethod   MonthlyCharges     TotalCharges            Churn
##                0                0               11                0
```

Rysunek 1: Brakujące wartości w danych

Widzimy, że braki występują w zmiennej *TotalCharges*(1)

```
data[is.na(data$TotalCharges), "tenure"]
```

```
##  [1] 0 0 0 0 0 0 0 0 0 0 0
```

Rysunek 2: Brakujące wartości w danych

możemy stwierdzić, że brak wartości w *TotalCharges*(2) dotyczy klientów, którzy dopiero rozpoczęli subskrypcję (mają `tenure` równy 0).

4 Wyniki

Dla zmiennych takich jak *gender*, *SeniorCitizen*, *Partner*, *Dependents*, *PhoneService*, *InternetService*, *Contract*, *PaymentMethod* czy *Churn* warto przedstawić ich rozkład.

```
table(data$gender)
```

```
##
## Female   Male
##   3488   3555
```

```
table(data$SeniorCitizen)
```

```
##
##    0    1
## 5901 1142
```

```
table(data$Partner)
```

```
##
##   No  Yes
## 3641 3402
```

```
table(data$Churn)
```

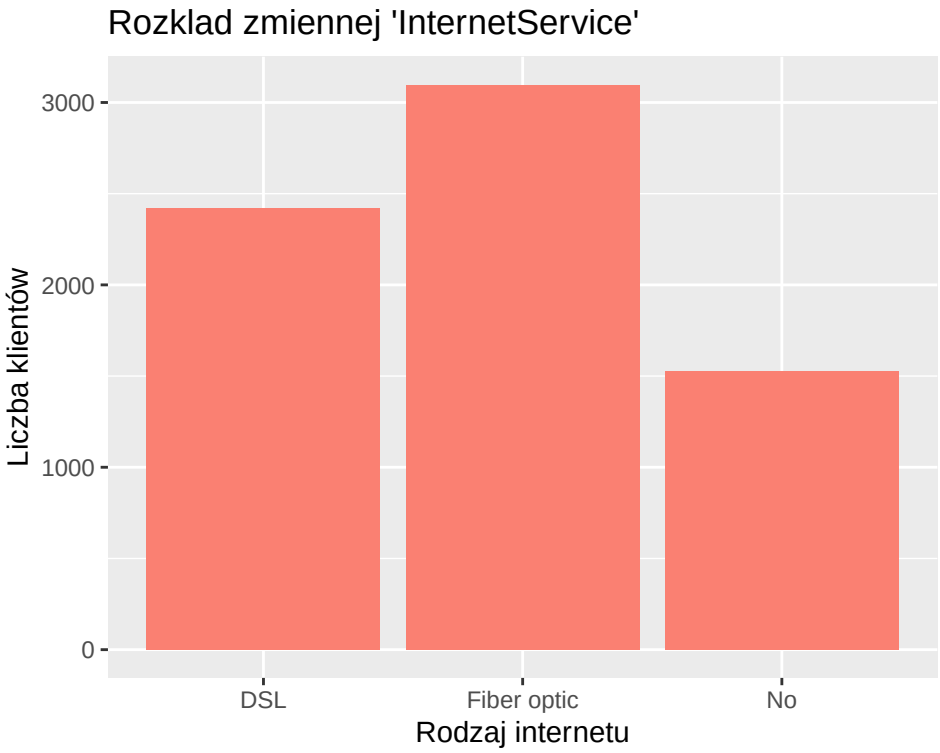
```
##
##   No  Yes
## 5174 1869
```

```
# Procentowy udział
prop.table(table(data$Churn)) * 100
```

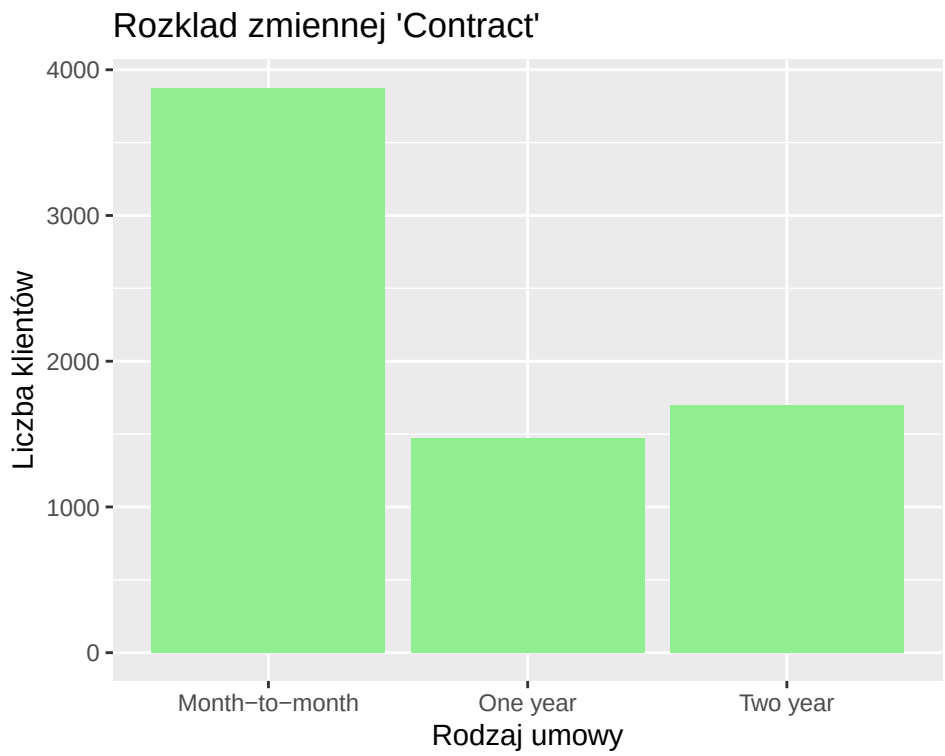
```
##
##       No      Yes
## 73.46301 26.53699
```

Rysunek 3: rozklady zmiennych

Wykreślimy wykresy słupkowe dla zmiennych *InternetService* oraz *Contract*.



Rysunek 4: ”Rodzaj internetu”



Rysunek 5: ”Rodzaj umowy”

Dla zmiennych takich jak *tenure*, *MonthlyCharges* oraz *TotalCharges* wyznaczymy:

- Liczebność obserwacji (n)
- Średnią (mean)
- Medianę
- Odchylenie standardowe (std)
- Wartości minimalne i maksymalne
- Kwartyle (Q1, Q3)
- Odchylenie standardowe

```
summary(data$tenure)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.00    9.00   29.00   32.37   55.00   72.00
```

```
summary(data$MonthlyCharges)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   18.25   35.50   70.35   64.76   89.85  118.75
```

```
summary(data$TotalCharges)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
##    18.8   401.4  1397.5  2283.3  3794.7  8684.8      11
```

```
cat("Odchylenie standardowe dla tenure:", sd(data$tenure, na.rm = TRUE), "\n")
```

```
## Odchylenie standardowe dla tenure: 24.55948
```

```
cat("Odchylenie standardowe dla MonthlyCharges:", sd(data$MonthlyCharges, na.rm = TRUE),
```

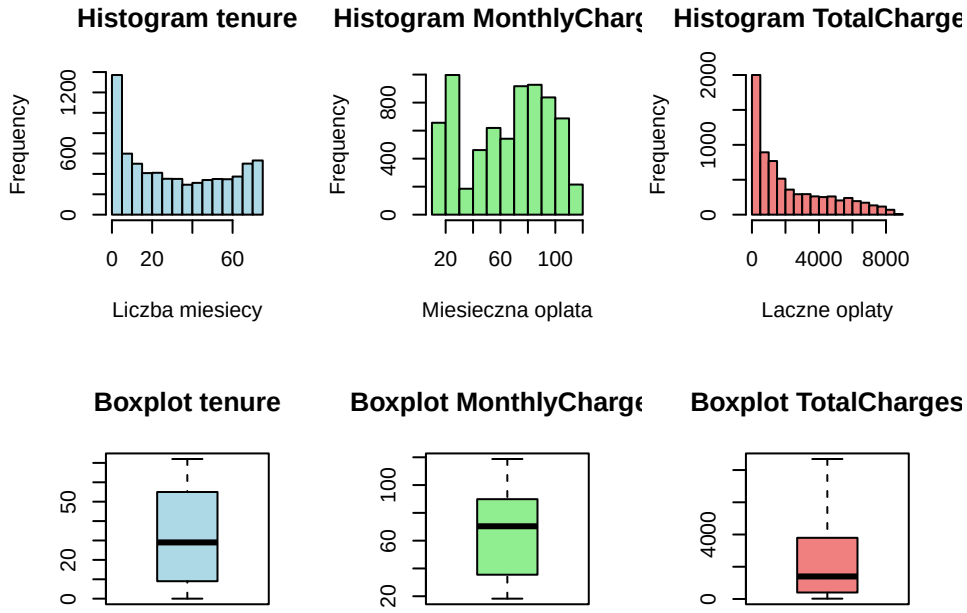
```
## Odchylenie standardowe dla MonthlyCharges: 30.09005
```

```
cat("Odchylenie standardowe dla TotalCharges:", sd(data$TotalCharges, na.rm = TRUE), "\r
```

```
## Odchylenie standardowe dla TotalCharges: 2266.771
```

Rysunek 6: Parmetry danych

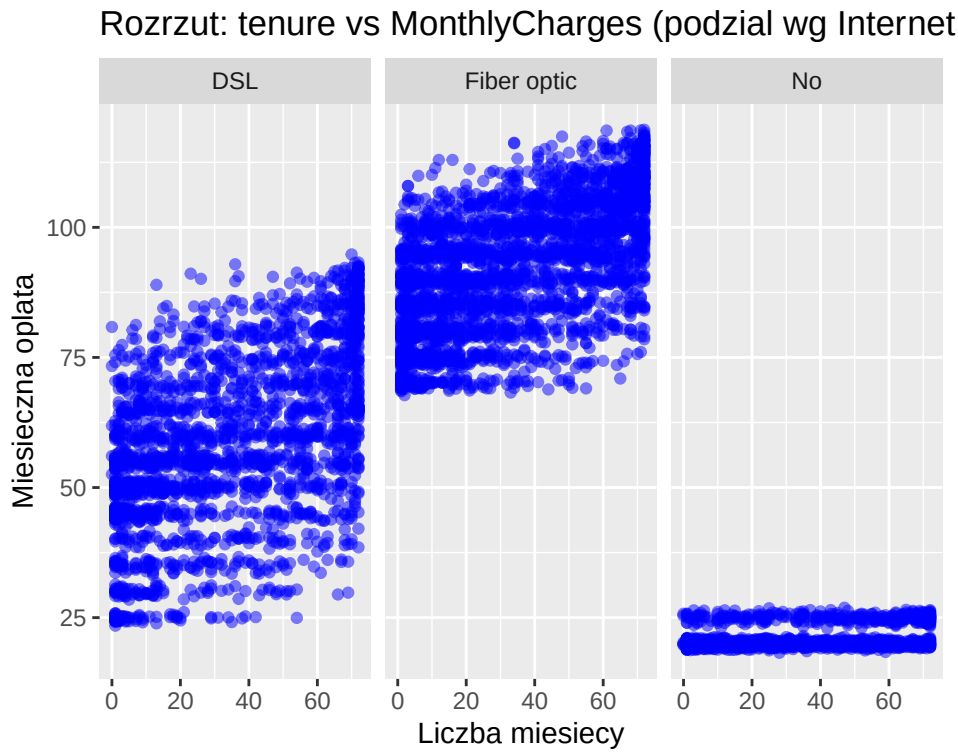
Przedstawimy histogramy i wykresy pudełkowe dla zmiennych *tenure*, *MonthlyCharges* i *TotalCharges*.



Rysunek 7: Wykresy pudełkowe zmiennych numerycznych

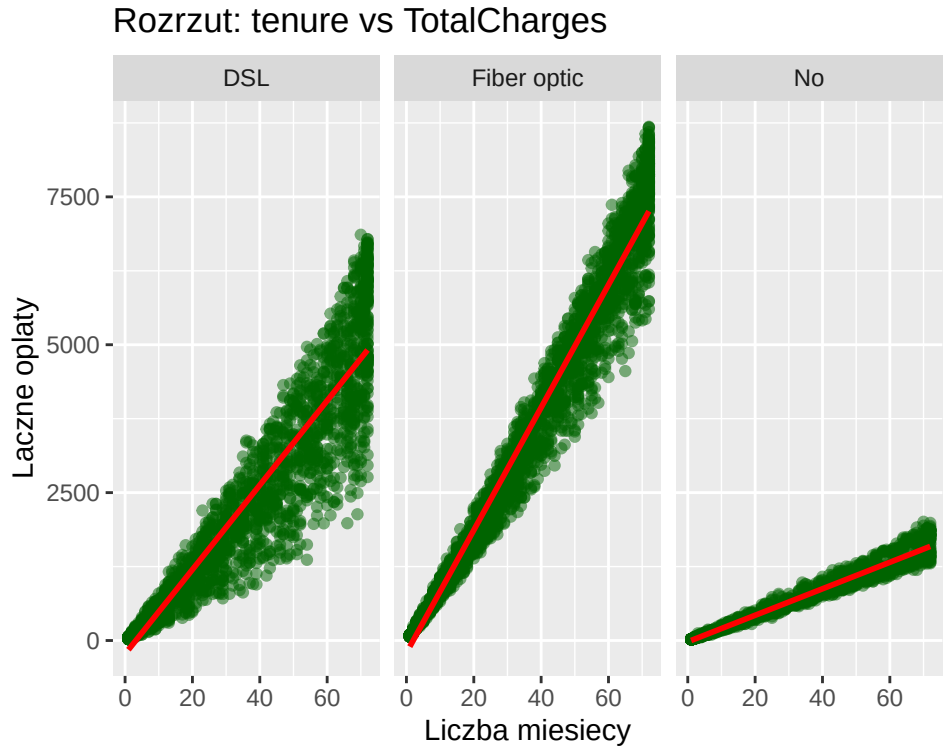
Zwróćmy uwage na:

Większość klientów ma bardzo krótki czas trwania subskrypcji(7) *(poniżej 10 miesięcy)* Opłaty skupiają się w 2 miejscach(7) co sugeruje zróżnicowaną oferte usług



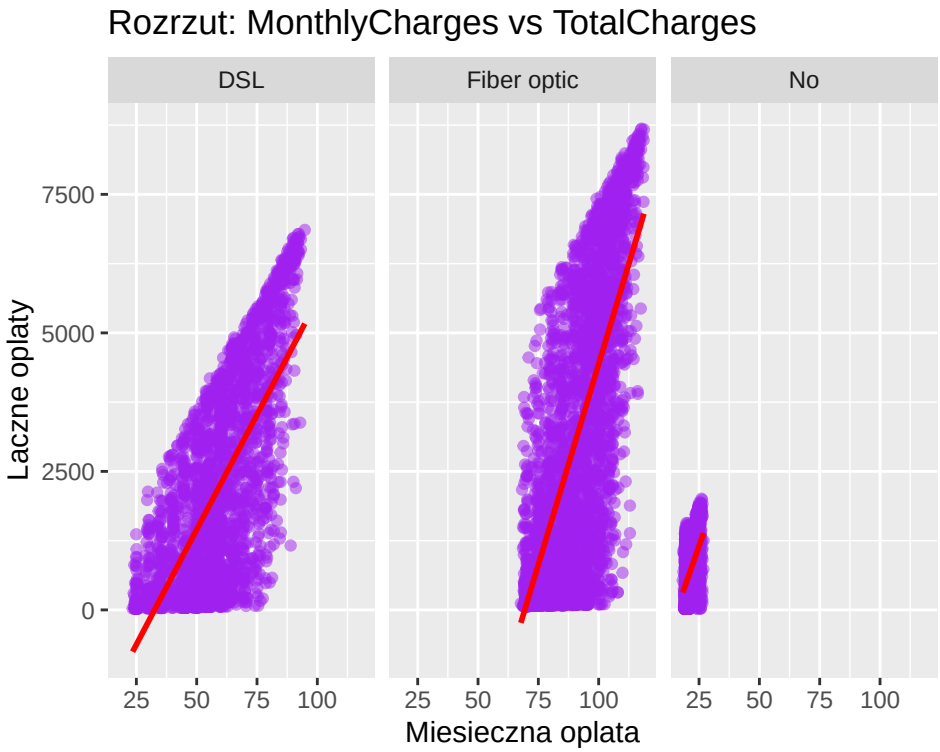
Rysunek 8: Zalezności między tenure a MonthlyCharges podziałem wg InternetService

Zuważmy, że istniej duża korelacja pomiędzy *InternetService* a *MonthlyCharges*(8).



Rysunek 9: Zalezności między tenure a TotalCharges podziałem wg InternetService

Istotnie *tenure* ma wpływ na *TotalCharges*(9) co nie jest zaksoczeniem.



Rysunek 10: Zalezności między TotalCharges a MonthlyCharges podziałem wg InternetService

Podobnie *MonthlyCharges* ma wpływ na *TotalCharges*(10).

Dodatkowo, wyznaczymy współczynniki korelacji między tymi zmiennymi:

```
## Korelacja między tenure a MonthlyCharges: 0.2478999
```

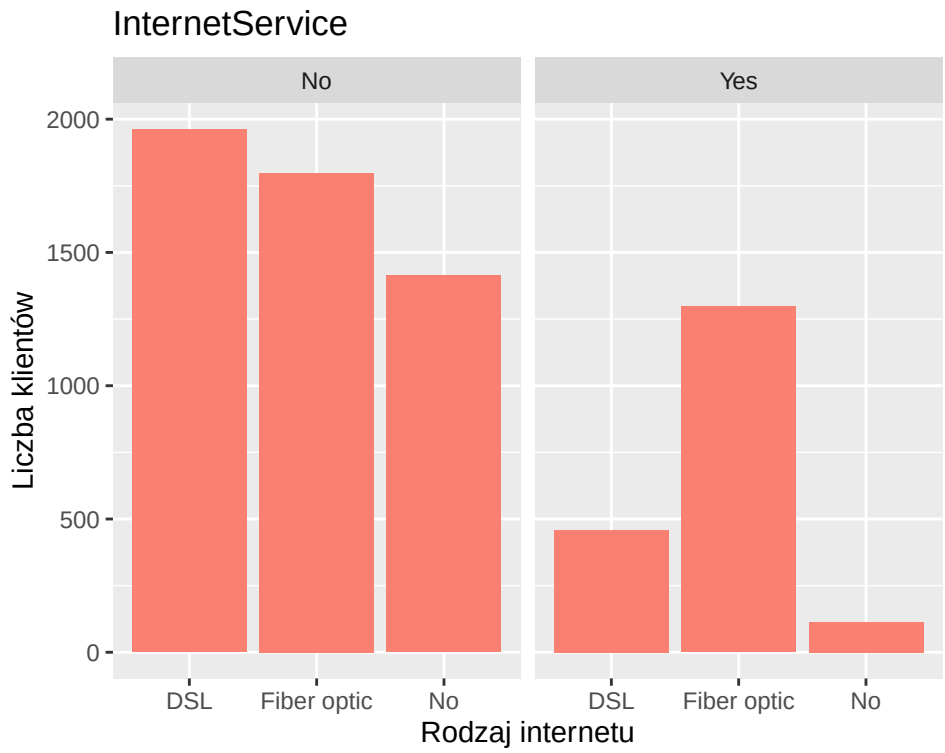
```
## Korelacja między tenure a TotalCharges: 0.8258805
```

```
## Korelacja między MonthlyCharges a TotalCharges: 0.6510648
```

Warto jednak zaznaczyć, że gdy podzielimy dane *MonthlyCharges* ze względu na *InternetService* współczynniki korelacji się zmienia

```
##         DSL Fiber optic          No
##   0.7178911   0.7135249   0.4844854
```

Przeanalizujmy teraz zmienną *Churn* (czy klient odszedł z firmy – Tak/Nie), aby lepiej zrozumieć, jakie czynniki mogą wpływać na decyzję o rezygnacji z usług.



Rysunek 11: Rodzaj internetu z podziałem na Churn

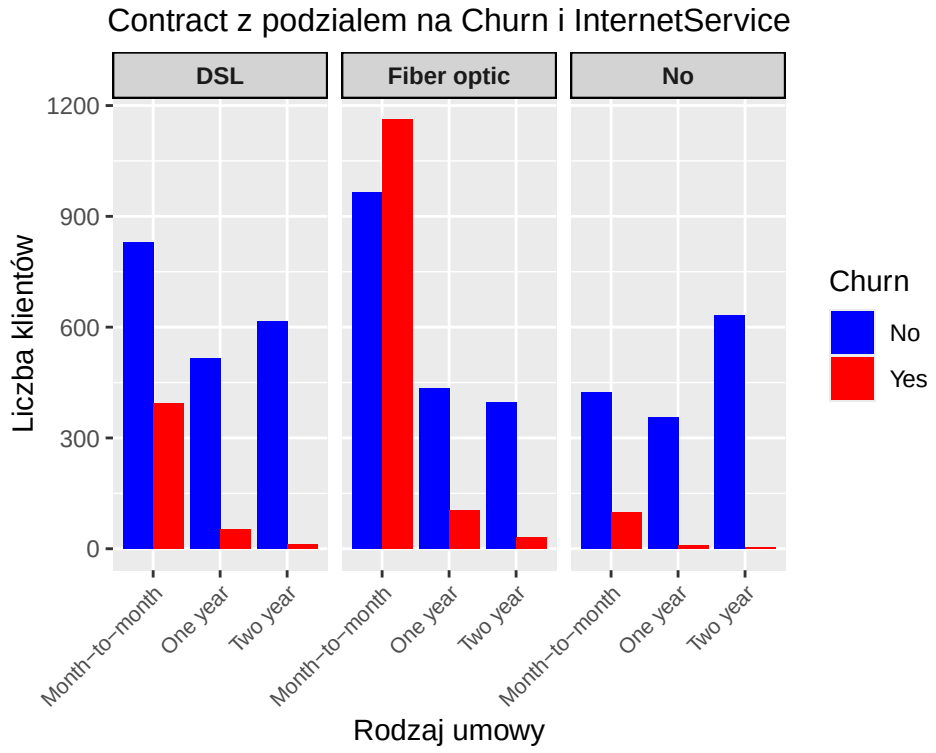
Zauważamy że najwięcej osób odchodzi mających umowe na swiatłowód(11)



Rysunek 12: ”Rodzaj umowy”

Zauważamy że najwięcej osób odchodzi mających umowy miesięczne(12). OnlnieSecurity jest mocno skorelowana z DeviceProtection(12)(oraz kilkoma innymi danymi jak *StreamingTV*). Zauważalnie więcej osób odeszło posługujących sie PaperlessBilling (oraz *Electronic check*) mających światłowód(12).

Należy się zatem zastanowić jakie są zależności między *Churn*, *InternetService* oraz *Contract*



Rysunek 13: "Rozkład zmiennej Contract z podziałem na Churn i InternetService"

Widzimy że bardzo dużo osób odeszło z umów o światłowód gdy umowa była miesięczna(13) Na podstwie tych danych można odrróżnić klientów dwuch grup.

5 Podsumowanie

Lista najważniejszych wniosków, jakie udało się wysnuć na podstawie przeprowadzonych analiz/eksperymentów:

- Seniorzy stanowią mniejszość klientów(3)
- Wskaźnik rezygnacji wynosi około 26%(3)
- Występują dwa główne segmenty cenowe(7)
- Posiadani partnera lub osoby na utrzymaniu nie wpływa na rezygnacje
- Istnieje szansa że firma wprowdziła cos w rodzaju pakietu promocyjnego na piewrszy miesiąc związaną z światłowodem co zniekształciłca dane lub te dane mogą sugerować, że wile osób miało problem światłowodem w ciągu kiklu pierwszych miesięcy(13)

Rozważmy jescze kroki jakie firma powinna podjąć by przeciwdziałać odchodzeniu klientów

- Zachęić nowych klientów na dłuższe umowy
- Skupić się na ewentulach problemach ze światłowodem