Regresja liniowa prosta — ściąga na kartkówkę

Model: $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ dla próby (x_i, y_i), $i = 1, \ldots, n$

1. Średnie próbkowe

$$\bar{x} = (1/n) \sum_{i=1}^{n} x_i \quad \bar{y} = (1/n) \sum_{i=1}^{n} y_i$$

2. Estymatory MNK (Metoda Najmniejszych Kwadratów)

Estymator nachylenia b_1 :

$$\mathbf{b_1 = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}) \,/\, \sum_{i=1}^{n} (x_i - \bar{x})^2}$$

Równoważny zapis (wygodny do obliczeń):

$$b_1 = \left(\sum x_i y_i - n \cdot \bar{x} \cdot \bar{y} \right) / \left(\sum x_i^2 - n \cdot \bar{x}^2 \right)$$

Estymator wyrazu wolnego b_0 :

$$\mathbf{b_0 = \bar{y} - b_1 \cdot \bar{x}}$$

Prosta regresji:

$$\hat{y}_i = b_0 + b_1 \cdot x_i$$

Interpretacja współczynników:

• **b_1** (nachylenie) — jeśli x wzrośnie o 1 jednostkę, to wartość y zmieni się **średnio** o b_1 jednostek (przy pozostałych warunkach stałych).

• **b_0** (wyraz wolny) — przewidywana wartość y, gdy x = 0. Uwaga: interpretacja ma sens tylko jeśli x = 0 leży w zakresie danych!

3. Estymator wariancji (wariancja resztowa)

Reszty (residua):

$$e_i = y_i - \hat{y}_i = y_i - b_0 - b_1 x_i$$

Nieobciążony estymator wariancji S^2 :

$$\mathbf{S^2 = (1 / (n - 2)) \cdot \sum_{i=1}^{n} e_i^2 = (1 / (n - 2)) \cdot \sum_{i=1}^{n} (y_i - \hat{y}_i)^2}$$

Dzielimy przez $(n - 2)$, bo estymujemy 2 parametry (β_0 i β_1), więc tracimy 2 stopnie swobody.

4. Rozkład sumy kwadratów

$$\mathbf{SST} = \sum (y_i - \bar{y})^2 \quad \mathbf{SSR} = \sum (\hat{y}_i - \bar{y})^2 \quad \mathbf{SSE} = \sum (y_i - \hat{y}_i)^2 \quad \mathbf{SST = SSR + SSE}$$

SST — całkowita zmienność y, SSR — zmienność wyjaśniona przez model, SSE — zmienność resztowa (niewyjaśniona).

5. Współczynnik determinacji R^2

$$\mathbf{R^2 = SSR / SST = 1 - SSE / SST}$$

$R^2 \in [0, 1]$ — równoważny zapis:

$$R^2 = 1 - \sum(y_i - \hat{y}_i)^2 / \sum(y_i - \bar{y})^2$$

Interpretacja R^2:

- R^2 mówi, jaka **część zmienności y jest wyjaśniona** przez model regresji (przez zmienną x).
- $R^2 = 0.85$ oznacza, że 85% zmienności y jest wyjaśnione przez zależność liniową od x.
- R^2 bliskie 1 → model dobrze dopasowany; R^2 bliskie 0 → model słabo dopasowany.

6. Współczynnik korelacji próbkowej r

$$\mathbf{r = \sum(x_i - \bar{x})(y_i - \bar{y}) / [\ \sum(x_i - \bar{x})^2\ ]^{1/2} \cdot [\ \sum(y_i - \bar{y})^2\ ]^{1/2}}$$

Związek z R^2:

$$R^2 = r^2 \quad r = \pm\sqrt{R^2} \text{ (znak taki jak znak } b_1)$$

Interpretacja r:

- $r \in [-1, 1]$. $|r|$ bliskie 1 → silna zależność liniowa; $r \approx 0$ → brak zależności liniowej.
- $r > 0$ → zależność rosnąca (gdy x rośnie, y rośnie); $r < 0$ → zależność malejąca.

|r|	Siła zależności
0.0 – 0.3	słaba
0.3 – 0.5	umiarkowana
0.5 – 0.7	znacząca
0.7 – 0.9	silna
0.9 – 1.0	bardzo silna

Kiedy model regresji liniowej ma sens?

- Gdy $|r|$ jest wystarczająco duże (orientacyjnie $|r| > 0.5$), zależność liniowa jest na tyle silna, że model regresji daje sensowne prognozy.
- Gdy $r \approx 0$, zależność liniowa między x i y praktycznie nie istnieje — model regresji liniowej nie ma sensu (ale może istnieć zależność nieliniowa!).

7. Prognozowana wartość

Dla nowej wartości x_0 prognoza y wynosi:

$$\mathbf{\hat{y}_0 = b_0 + b_1 \cdot x_0}$$

Prognoza jest najdokładniejsza w pobliżu $\bar{x}$. Im dalej x_0 od zakresu danych, tym mniejsza wiarygodność prognozy (ekstrapolacja!).